

---

# AMPLIACIÓN DE LA TEORÍA DE LA PROBABILIDAD

---

*Basado en las clases y apuntes de Antonio Jesús Barrera García*

Autor:  
Jorge Rodríguez Domínguez



# Índice general



# Capítulo 1

## Función de distribución

### 1.1. Propiedades

**Definición 1.1.** Sea  $X$  una variable aleatoria en  $(\Omega, \mathcal{A}, P)$ ,  $P_X$  medida de probabilidad inducida por  $X$  en  $(\mathbb{R}, \mathcal{B})$ . La función de distribución asociada a  $X$  es  $F : \mathbb{R} \rightarrow [0, 1]$  dada por

$$F(a) = P_X((-\infty, a]) \equiv P(X \leq a)$$

Las propiedades de  $F$  son

1.  $F$  es monótona no decreciente.
2.  $\lim_{x \rightarrow -\infty} F(x) = 0$  y  $\lim_{x \rightarrow \infty} F(x) = 1$ .
3.  $F$  es continua por la derecha, es decir,  $\lim_{h \rightarrow 0^+} F(x+h) = F(x)$  para todo  $x \in \mathbb{R}$ .
4. Existe el límite por la izquierda, es decir,  $\lim_{h \rightarrow 0^-} F(x+h) = F(x^-) = F(x) - P_X(\{x\})$  para todo  $x \in \mathbb{R}$ .

**Teorema 1.2** (de correspondencia). Si  $F : \mathbb{R} \rightarrow [0, 1]$  es una función

- Monótona no decreciente.
- $F(-\infty) = 0$  y  $F(\infty) = 1$ .
- Continua por la derecha

Entonces existe (y es única) una medida de probabilidad  $P_F$  que  $(\mathbb{R}, \mathcal{B})$  tal que  $F$  es su función de distribución.

**Definición 1.3.** Sea  $F$  una función de distribución. Definimos

- El conjunto de continuidad de  $F$  como

$$C(F) = \{x \in \mathbb{R} : F(x) = F(x^-)\}$$

- El conjunto de discontinuidad de  $F$  como

$$D(F) = \{x \in \mathbb{R} : F(x) - F(x^-) > 0\}$$

**Observación 1.4.** Es fácil ver que  $D(F) = \overline{C(F)}$ .

**Proposición 1.5.**  $D(F)$  es a lo sumo numerable.

*Demostración.* Definimos la sucesión de conjuntos

$$D_n(F) = \left\{ x \in \mathbb{R} : F(x) - F(x^-) \geq \frac{1}{n} \right\}$$

Es claro que  $\{D_n\}$  es una sucesión creciente. Veamos que  $\#D_n(F)$  es finito. Por el teorema de correspondencia, existe una única  $P_F$  medida de probabilidad asociada a  $F$ , es decir,  $P_F(\{x\}) = F(x) - F(x^-)$  para todo  $x \in \mathbb{R}$ . Podemos usar que  $P_F$  para "medir"  $D_n(F)$  de la siguiente manera:

$$P_F(D_n(F)) = \sum_{x \in D_n(F)} P_F(\{x\}) \geq \sum_{x \in D_n(F)} \frac{1}{n} = \frac{1}{n} \#D_n(F)$$

de donde deducimos que  $\#D_n(F) \leq n$ . Como  $\{D_n\}$  es una sucesión creciente, entonces

$$D(F) = \lim_{n \rightarrow \infty} D_n(F) = \bigcup_{n=1}^{\infty} D_n(F)$$

lo que demuestra que  $D(F)$  es a lo sumo numerable.  $\square$

**Corolario 1.6.**  $C(F)$  es denso en  $\mathbb{R}$ .

*Demostración.* Como  $D(F) = \overline{C(F)}$  y  $D(F)$  es a lo sumo numerable, tenemos que si  $x \in \mathbb{R}$ , o bien  $x \in C(F)$ , o bien  $x \in D(F)$ , por lo que cualquier bola  $B(x, \varepsilon)$  contiene puntos de  $C(F)$ .  $\square$

**Proposición 1.7.** Sean  $F$  y  $G$  funciones de distribución tales que  $F(x) = G(x)$  para todo  $x \in E \subset \mathbb{R}$  con  $E$  denso en  $\mathbb{R}$ . Entonces  $F(x) = G(x)$  para todo  $x \in \mathbb{R}$ .

*Demostración.* Sea  $x \in \mathbb{R}$ . Como  $E$  es denso en  $\mathbb{R}$ , existe una sucesión  $\{x_n\} \subset E$  tal que  $x_n \rightarrow x$  de forma decreciente ( $x_n \downarrow x$ ) cuando  $n \rightarrow \infty$ . Entonces  $F(x_n) = G(x_n)$  para todo  $x_n \in E$  (por hipótesis). Como  $F$  y  $G$  son funciones de distribución, tenemos que

$$\begin{aligned} \lim_{n \rightarrow \infty} F(x_n) &= F(x) \\ \lim_{n \rightarrow \infty} G(x_n) &= G(x) \end{aligned}$$

Por la unicidad del límite,  $F(x) = G(x)$ .  $\square$

**Definición 1.8.** La función de masa de probabilidad es  $p : \mathbb{R} \rightarrow [0, 1]$  dada por

$$p(x) = P_F(\{x\}).$$

**Definición 1.9.** Sea  $X$  una variable aleatoria con función de distribución  $F$  y función de masa  $p$ . Diremos que

- $X$  es una variable aleatoria discreta cuando

$$\sum_{x \in D(F)} p(x) = 1$$

- $X$  es una variable aleatoria continua cuando  $p(x) = 0$  para todo  $x \in \mathbb{R}$ .
- $X$  es una variable aleatoria singular si existe  $B \in \mathcal{B}$  tal que  $m(B) = 0$  (medida de Lebesgue) y  $P_X(B) = 1$ .
- $X$  es una variable aleatoria absolutamente continua si para cualquier  $B \in \mathcal{B}$  con  $m(B) = 0$  se tiene que  $P_X(B) = 0$ .

**Teorema 1.10** (Radon-Nikodym). Sea  $F$  función de distribución. Entonces  $F$  es absolutamente continua si y solo si existe una función medible  $f$  no negativa y finita tal que para cualquier  $a < b$ ,  $a, b \in \mathbb{R}$  se tiene que

$$F(b) - F(a) = \int_a^b f(x) dx.$$

**Teorema 1.11** (Primera descomposición). *Toda función de distribución  $F$  se puede descomponer de la forma*

$$F = \alpha F_d + (1 - \alpha) F_c,$$

donde  $0 \leq \alpha \leq 1$ ,  $F_d$  es la función de distribución de una variable aleatoria discreta y  $F_c$  es la función de distribución de una variable aleatoria continua.

*Demostración.* Sea  $D(F)$  el conjunto de discontinuidad de  $F$ . Definimos  $\alpha = \sum_{x \in D(F)} p(x)$ , donde  $p$  es la función de masa.

- Si  $\alpha = 0$ , entonces  $F = F_c$  y es continua.
- Si  $\alpha = 1$ , entonces  $F = F_d$  y es discreta.
- Si  $0 < \alpha < 1$ , definimos

$$F_d(x) = \frac{1}{\alpha} \sum_{D(F) \ni y \leq x} p(y)$$

$$F_c(x) = \frac{1}{1 - \alpha} (F(x) - \alpha F_d(x))$$

Por definición,  $F_d$  es discreta. Veamos que  $F_c$  es continua, para ello hay que ver que  $F_c(x) - F_c(x^-) = 0$  para todo  $x \in \mathbb{R}$ . Sea  $x \in \mathbb{R}$ , entonces

$$\begin{aligned} F_c(x) - F_c(x^-) &= \frac{1}{1 - \alpha} (F(x) - \alpha F_d(x) - F(x^-) + \alpha F_d(x^-)) \\ &= \frac{1}{1 - \alpha} (F(x) - F(x^-) - \alpha (F_d(x) - F_d(x^-))) \\ &= \frac{1}{1 - \alpha} \left( p(x) - \alpha \frac{1}{\alpha} p(x) \right) = 0 \end{aligned}$$

□

**Lema 1.12.** *Sea  $F$  una función de distribución. Entonces*

- a) *Existe  $F'$  en casi todo punto, es no negativa y finita.*
- b)  $\int_a^b F'(x) dx \leq F(b) - F(a)$  para todo  $a < b$ ,  $a, b \in \mathbb{R}$ .
- c) *Siendo  $F_{ac} = \int_{-\infty}^x F'(t) dt$  y  $F_s(x) = F(x) - F_{ac}(x)$ , entonces  $F'_{ac}(x) = F'(x)$  en casi todo punto y  $F'_s(x) = 0$ .*

**Teorema 1.13** (Segunda descomposición). *Toda función de distribución  $F$  se puede descomponer de la forma*

$$F = \beta F_{ac} + (1 - \beta) F_s,$$

donde  $0 \leq \beta \leq 1$ ,  $F_{ac}$  es la función de distribución de una variable aleatoria absolutamente continua y  $F_s$  es la función de distribución de una variable aleatoria singular.

*Demostración.* Sea  $f \equiv F'$  donde exista. Definimos  $\beta = \int_{-\infty}^{\infty} f(x) dx$ .

- Si  $\beta = 1$ , entonces  $F = F_{ac}$  y es absolutamente continua.
- Si  $\beta = 0$ , entonces  $F = F_s$  y es singular.
- Si  $0 < \beta < 1$ , definimos

$$F_{ac}(x) = \frac{1}{\beta} \int_{-\infty}^x f(t) dt$$

$$F_s(x) = \frac{1}{1 - \beta} (F(x) - \beta F_{ac}(x))$$

Por definición,  $F_{ac}$  es absolutamente continua. Veamos que  $F_s$  es singular, para ello hemos de probar que  $F'_s = 0$ .

$$F'_s(x) = \frac{1}{1-\beta} \left( f(x) - \beta \frac{1}{\beta} f(x) \right) = 0$$

□

**Observación 1.14.** Aplicando la primera descomposición a  $F_s$ , tenemos que

$$\begin{aligned} F &= \beta F_{ac} + (1-\beta)[\alpha F_d + (1-\alpha)F_{cs}] \\ &= \beta F_{ac} + (1-\beta)\alpha F_d + (1-\beta)(1-\alpha)F_{cs} \\ &= \beta F_{ac} + \gamma F_d + (1-\beta-\gamma)F_{cs} \end{aligned}$$

siendo  $\gamma = (1-\beta)\alpha$  y  $\beta + \gamma \leq 1$ .

Recordemos ahora el concepto de esperanza matemática.

**Definición 1.15.** Sea  $X$  una variable aleatoria en  $(\Omega, \mathcal{A}, P)$ . Definimos la esperanza de  $X$  como  $E(X) = \int_{\Omega} X \, dP$ .

Usando el siguiente Teorema de Teoría de la Medida e Integración

**Teorema 1.16.** Sean  $(X, M, \mu)$  e  $(Y, \mathcal{N}, \nu)$  dos espacios de medida y sea  $T : X \rightarrow Y$  una aplicación  $(M, \mathcal{N})$ -medible que conserva las medidas. Si  $g : Y \rightarrow [0, +\infty]$  es medible entonces

$$\int_Y g \, d\nu = \int_X g \circ T \, d\mu.$$

es fácil ver que

- Si  $F$  es la función de distribución de una variable aleatoria absolutamente continua, entonces

$$E(X) = \int_{\mathbb{R}} x \cdot f(x) \, dx.$$

- Si  $F$  es la función de distribución de una variable aleatoria discreta, entonces

$$E(X) = \sum_{x \in D(F)} x \cdot p(x).$$

## 1.2. Convolución de funciones de distribución

**Definición 1.17.** Sean  $F$  y  $G$  funciones de distribución. Definimos la convolución de  $F$  y  $G$  como la función

$$(F * G)(z) = \int_{\mathbb{R}} F(z-y) \, dG(y), \quad z \in \mathbb{R}.$$

**Proposición 1.18.**  $F * G$  es una función de distribución.

*Demostración.* 1.  $F * G$  es monótona no decreciente. Sean  $a < b$ ,  $a, b \in \mathbb{R}$ , entonces

$$(F * G)(a) = \int_{\mathbb{R}} F(a-y) \, dG(y) \leq \int_{\mathbb{R}} F(b-y) \, dG(y) = (F * G)(b),$$

donde usamos que  $F$  es función de distribución.



2.  $\lim_{x \rightarrow -\infty} (F * G)(x) = 0$  y  $\lim_{x \rightarrow \infty} (F * G)(x) = 1$ .

$$\begin{aligned} \lim_{x \rightarrow -\infty} (F * G)(x) &= \lim_{x \rightarrow -\infty} \int_{\mathbb{R}} F(x-y) dG(y) = \int_{\mathbb{R}} \lim_{x \rightarrow -\infty} F(x-y) dG(y) = \int_{\mathbb{R}} 0 dG(y) = 0 \\ \lim_{x \rightarrow \infty} (F * G)(x) &= \lim_{x \rightarrow \infty} \int_{\mathbb{R}} F(x-y) dG(y) = \int_{\mathbb{R}} \lim_{x \rightarrow \infty} F(x-y) dG(y) = \int_{\mathbb{R}} 1 dG(y) = 1 \end{aligned}$$

donde usamos que  $F$  y  $G$  son funciones de distribución.

3.  $F * G$  es continua por la derecha, es decir,  $\lim_{h \rightarrow 0^+} (F * G)(x+h) = (F * G)(x)$  para todo  $x \in \mathbb{R}$ .

$$\begin{aligned} \lim_{h \rightarrow 0^+} (F * G)(x+h) &= \lim_{h \rightarrow 0^+} \int_{\mathbb{R}} F(x+h-y) dG(y) \\ &= \int_{\mathbb{R}} \lim_{h \rightarrow 0^+} F(x+h-y) dG(y) \\ &= \int_{\mathbb{R}} F(x-y) dG(y) = (F * G)(x) \end{aligned}$$

donde usamos el Teorema de la Convergencia Dominada y que  $F$  es función de distribución.

4. Existe el límite por la izquierda, es decir,  $\lim_{h \rightarrow 0^-} (F * G)(x+h) = (F * G)(x^-)$  para todo  $x \in \mathbb{R}$ .

$$\begin{aligned} \lim_{h \rightarrow 0^-} (F * G)(x+h) &= \lim_{h \rightarrow 0^-} \int_{\mathbb{R}} F(x+h-y) dG(y) \\ &= \int_{\mathbb{R}} \lim_{h \rightarrow 0^-} F(x+h-y) dG(y) \\ &= \int_{\mathbb{R}} F(x^- - y) dG(y) = (F * G)(x^-) \end{aligned}$$

donde usamos el Teorema de la Convergencia Dominada y que  $F$  es función de distribución.  $\square$

**Teorema 1.19.** Sean  $X$  e  $Y$  variables aleatorias independientes con funciones de distribución  $F_X$  y  $F_Y$  respectivamente. Entonces  $F_X * F_Y$  es la función de distribución de  $X + Y$ .

*Demostración.* Definimos la variable aleatoria  $Z = X + Y$ . Si llamamos  $F_{(X,Y)}$  a la función de distribución conjunta del par  $(X, Y)$ , entonces la función de distribución de  $Z$  es

$$\begin{aligned} F_Z(z) &= P(Z \leq z) = P(X + Y \leq z) = \int_{\{(x,y) \in \mathbb{R}^2 : x+y \leq z\}} dF_{(X,Y)}(x,y) \\ &= \int_{-\infty}^{\infty} \int_{-\infty}^{z-y} dF_X(x) dF_Y(y) = \int_{\mathbb{R}} F_X(z-y) dF_Y(y) = (F_X * F_Y)(z) \end{aligned}$$

$\square$

**Teorema 1.20.** Si  $F$  es una función de distribución absolutamente continua con densidad  $f$ , entonces  $F * G$  es una función de distribución absolutamente continua con densidad

$$(f * G)(s) = \int_{-\infty}^{\infty} f(s-y) dG(y).$$

*Demostración.*

$$\begin{aligned} (F * G)(z) &= \int_{-\infty}^{\infty} \int_{-\infty}^{z-y} f(s) ds dG(y) = \int_{-\infty}^{\infty} \int_{-\infty}^z f(s-y) ds dG(y) \\ &= \int_{-\infty}^z \int_{-\infty}^{\infty} f(s-y) dG(y) ds \end{aligned}$$

$\square$

**Teorema 1.21.** Si  $F$  y  $G$  son funciones de distribución absolutamente continuas con densidades  $f$  y  $g$  respectivamente, entonces  $F * G$  es una función de distribución absolutamente continua con densidad  $f * g$ .

*Demostración.*

$$\begin{aligned}(F * G)(z) &= \int_{-\infty}^{\infty} \int_{-\infty}^{z-y} f(s) \, ds \, dG(y) = \int_{-\infty}^{\infty} \int_{-\infty}^z f(s-y) \, ds \, dG(y) \\ &= \int_{-\infty}^z \int_{-\infty}^{\infty} f(s-y) \, dG(y) \, ds = \int_{-\infty}^z \int_{-\infty}^{\infty} f(s-y)g(y) \, dy \, ds\end{aligned}$$

□

### 1.3. Convergencia en distribución

Para cada  $n \in \mathbb{N}$ , tenemos una variable aleatoria  $X_n$  en  $(\Omega, \mathcal{A}_n, P_n)$ . De esta forma  $\{X_n\}$  tiene una sucesión asociada  $\{F_n\}$  de funciones de distribución.

**Definición 1.22.** Sea  $F$  y  $F_n$ ,  $n \in \mathbb{N}$ , funciones de distribución. Decimos que la sucesión  $\{F_n\}$  converge a  $F$  débilmente (o en distribución), y se denota como  $F_n \xrightarrow{d} F$ , cuando

$$\lim_{n \rightarrow \infty} F_n(x) = F(x)$$

para todo  $x \in C(F)$ .

**Teorema 1.23.** El límite débil es único.

*Demostración.* Sea  $\{F_n\}$  una sucesión de funciones de distribución tal que  $F_n \xrightarrow{d} F$  y  $F_n \xrightarrow{d} G$ , con  $F$  y  $G$  funciones de distribución. Entonces

$$\begin{aligned}\lim_{n \rightarrow \infty} F_n(x) &= F(x) \quad \forall x \in C(F) \\ \lim_{n \rightarrow \infty} F_n(x) &= G(x) \quad \forall x \in C(G)\end{aligned}$$

De aquí

$$F(x) = G(x) \quad \forall x \in C(F) \cap C(G)$$

Como  $C(F)$  y  $C(G)$  son densos en  $\mathbb{R}$ , entonces  $C(F) \cap C(G)$  es denso en  $\mathbb{R}$  y por tanto,  $F \equiv G$  para todo  $x \in \mathbb{R}$ . □

**Definición 1.24.** La sucesión de variables aleatorias  $\{X_n\}$  converge en distribución a otra variable aleatoria  $X$  cuando  $F_n \xrightarrow{d} F$ , siendo  $F_n$  y  $F$  las funciones de distribución asociadas a  $X_n$  y  $X$  respectivamente.

**Definición 1.25.** Sean  $P$  y  $P_n$ ,  $n \in \mathbb{N}$ , medidas de probabilidad en  $(\mathbb{R}, \mathcal{B})$ . Decimos que la sucesión de medidas  $\{P_n\}$  converge débilmente a  $P$  cuando

$$\lim_{n \rightarrow \infty} P_n((a, b]) = P((a, b])$$

para todo  $a < b$  con  $P(a) = P(b) = 0$ .

**Lema 1.26.**  $F_n \xrightarrow{d} F$  si y solo si para todo  $x \in \mathbb{R}$  se tiene que

$$\limsup_{n \rightarrow \infty} F_n(x) \leq F(x) \quad \text{y} \quad \liminf_{n \rightarrow \infty} F_n(x^-) \geq F(x).$$

*Demostración.*  $\boxed{\Leftarrow}$  Tenemos que para todo  $x \in \mathbb{R}$

$$F(x^-) \leq \liminf_{n \rightarrow \infty} F_n(x) \leq \limsup_{n \rightarrow \infty} F_n(x) \leq F(x).$$

Si  $x \in C(F)$ , entonces  $F(x) = F(x^-)$ , y en consecuencia

$$\liminf_{n \rightarrow \infty} F_n(x) = \limsup_{n \rightarrow \infty} F_n(x) = F(x),$$

es decir,  $F_n \xrightarrow{d} F$ .

$\boxed{\Rightarrow}$  Sea  $x \in \mathbb{R}$  e  $y \in C(F)$ ,  $y > x$ . Entonces

$$F_n(x) \leq F(y) \Rightarrow \limsup_{n \rightarrow \infty} F_n(x) \leq \limsup_{n \rightarrow \infty} F_n(y) = \lim_{n \rightarrow \infty} F_n(y) = F(y).$$

Como  $C(F)$  es denso en  $\mathbb{R}$ , podemos tomar una sucesión de puntos de  $C(F)$  que tienda a  $x$  (en nuestro caso, de manera decreciente), y así

$$\limsup_{n \rightarrow \infty} F_n(x) \leq \lim_{y \downarrow x} F(y) = F(x),$$

donde la última igualdad es cierta por ser  $F$  función de distribución. Usando un argumento análogo, sea  $z < x$ ,  $z \in C(F)$ , entonces

$$\liminf_{n \rightarrow \infty} F_n(x) \geq \liminf_{n \rightarrow \infty} F_n(z) = F(z).$$

Al igual que antes, podemos tomar una sucesión de puntos de  $C(F)$  que tienda a  $x$  (en nuestro caso, de manera creciente), y así

$$\liminf_{n \rightarrow \infty} F_n(x) \geq \lim_{z \uparrow x} F(z) = F(x^-).$$

□

**Teorema 1.27** (Helly-Bray). Sean  $F_n, F$  funciones de distribución ( $n > 0$ ). Entonces  $F_n \xrightarrow{d} F$  si y solo si para toda función  $g$  real, continua y acotada se tiene que

$$\lim_{n \rightarrow \infty} \int_{\mathbb{R}} g(x) dF_n(x) = \int_{\mathbb{R}} g(x) dF(x).$$

**Definición 1.28.** Una función  $F$  se dice función de distribución impropia si verifica:

- (i) Es monótona no decreciente.
- (ii) Es continua por la derecha.
- (iii) Para cada  $x \in \mathbb{R}$  existe

$$\lim_{h \rightarrow 0^-} F(x+h) = F(x^-).$$

- (iv)

$$\lim_{x \rightarrow \infty} F(x) > 0 \quad \text{ò} \quad \lim_{x \rightarrow \infty} F(x) < 1.$$

**Definición 1.29.** Sea  $\{F_n\}$  sucesión de funciones de distribución y  $F$  función de distribución (propia o impropia). Decimos que  $\{F_n\}$  converge de forma vaga a  $F$  si

$$\lim_{n \rightarrow \infty} F_n(x) = F(x)$$

para todo  $x \in C(F)$ . Se denota como  $F_n \xrightarrow{v} F$ .

**Observación 1.30.** Es claro que  $F_n \xrightarrow{d} F \implies F_n \xrightarrow{v} F$ .

**Teorema 1.31.** Supongamos que  $F_n \xrightarrow{v} F$ , siendo  $F$  una función de distribución impropia. Sea  $g$  una función real y continua en  $[a, b]$ , siendo  $a < b$  y  $a, b \in C(F)$ . Entonces

$$\lim_{n \rightarrow \infty} \int_a^b g(x) dF_n(x) = \int_a^b g(x) dF(x)$$

**Teorema 1.32.** Supongamos que  $F_n \xrightarrow{v} F$ , siendo  $F$  una función de distribución impropia. Sea  $g$  una función real y continua en  $\mathbb{R}$  y tal que  $g(+\infty) = g(-\infty) = 0$ . Entonces

$$\lim_{n \rightarrow \infty} \int_{\mathbb{R}} g(x) dF_n(x) = \int_{\mathbb{R}} g(x) dF(x)$$

**Lema 1.33.**  $\{F_n\}$  converge vagamente si y solo si converge puntualmente en algún conjunto denso  $D \subset \mathbb{R}$ .

*Demostración.*  $\implies$  Es directo, pues basta tomar  $D = C(F)$ .

$\impliedby$  Sea  $r \in D$ , definimos

$$F_D(r) = \lim_{n \rightarrow \infty} F_n(r).$$

Sabemos que  $0 \leq F_D(r) \leq 1$  para cada  $r \in D$ . Si  $s \in D$  es tal que  $r < s$ , entonces

$$F_D(r) = \lim_{n \rightarrow \infty} F_n(r) \leq \lim_{n \rightarrow \infty} F_n(s) = F_D(s),$$

pues  $F_n$  es función de distribución, lo que nos dice que  $F_D$  es monótona no decreciente. Ahora, sea  $x \in \mathbb{R}$ , definimos

$$F(x) = \lim_{r \downarrow x, r \in D} F_D(r) = \inf \Pi_x,$$

donde

$$\Pi_x = \{F_D(r) : r > x, r \in D\}.$$

Es claro que  $0 \leq F(x) \leq 1$  para cada  $x \in \mathbb{R}$ . Veamos que  $F$  es continua por la derecha, para ello hemos de probar que  $F(x) = F(x^+)$  para cada  $x \in \mathbb{R}$ . Sean  $x, y \in \mathbb{R}$ ,  $r \in D$  tales que  $x < y < r$ , entonces

$$F(y) = \inf \Pi_y \leq F_D(r),$$

pues  $F_D(r) \in \Pi_y$ . Entonces

$$F(x^+) = \lim_{y \downarrow x} F(y) \leq F_D(r).$$

Además  $F(x^+) \leq \inf \Pi_x = F(x)$  (pues  $x^+ > x$ ) y como  $F$  es monótona no decreciente, tenemos que  $F(x) \leq F(x^+)$ , por tanto,  $F(x) = F(x^+)$ .

Con todo esto, hemos probado que  $F$  es función de distribución impropia. Veamos que  $F_n \xrightarrow{v} F$  en  $C(F)$ . Sean  $x \in C(F)$ ,  $r', s \in D$  tales que  $r' < x < s$ , entonces

$$\begin{aligned} \inf \Pi_r = F(r) &\leq F_D(r) \leq \lim_{n \rightarrow \infty} F_n(r) = \lim_{n \rightarrow \infty} \inf F_n(r) \leq \lim_{n \rightarrow \infty} \inf F_n(x) \\ &\leq \limsup_{n \rightarrow \infty} F_n(s) = F_D(s) \leq F(s) = \inf \Pi_s. \end{aligned}$$

Tomando  $r < r'$ ,  $r \in D$ , tenemos que

$$\inf \Pi_r = F(r) \leq F_D(r').$$

Si tomamos límite  $r \uparrow x$ ,  $s \downarrow x$ , tenemos que

$$F(x) \leq \liminf_{n \rightarrow \infty} F_n(x) \leq \limsup_{n \rightarrow \infty} F_n(x) \leq F(x),$$

de donde concluimos que

$$\lim_{n \rightarrow \infty} F_n(x) = F(x)$$

para cada  $x \in C(F)$ , es decir,  $F_n \xrightarrow{v} F$ . □

**Teorema 1.34** (Principio de selección de Helly). *Dada  $\{F_n\}$ ,  $n \in \mathbb{N}$ , sucesión de funciones de distribución, existe alguna subsucesión que converge vagamente.*

**Definición 1.35.** Sea  $\mathcal{H}$  familia de funciones de distribución. Diremos que  $\mathcal{H}$  es ajustada si para cada  $\varepsilon > 0$ , existe  $a > 0$  tal que

$$P_F((-a, a]) > 1 - \varepsilon,$$

para cada  $F \in \mathcal{H}$ .

**Definición 1.36.** Sea  $\mathcal{H}$  una familia de funciones de distribución. Diremos que  $\mathcal{H}$  es relativamente compacta (respecto de la convergencia debil) si cada sucesión  $\{F_n\}$ ,  $F_n \in \mathcal{H}$ , tiene un subsucesión convergente (de forma debil, a un límite no esté necesariamente en  $\mathcal{H}$ ).

**Teorema 1.37** (Prokhorov). *Sea  $\mathcal{H}$  una familia de funciones de distribución.  $\mathcal{H}$  es relativamente compacta si y solo si es ajustada.*



## Capítulo 2

# Función característica

### 2.1. Función característica

**Definición 2.1.** Sea  $X$  una variable aleatoria en  $(\Omega, \mathcal{A}, P)$ . La función característica asociada a  $X$  es  $\varphi_X : \mathbb{R} \rightarrow \mathbb{C}$  dada por

$$\varphi_X(t) = E[e^{itX}] = \int_{\mathbb{R}} e^{itx} dF(x).$$

Si  $Y : \Omega \rightarrow \mathbb{R}^d$ ,  $d \geq 1$ , es un vector de variables aleatorias, entonces  $\varphi_Y : \mathbb{R}^d \rightarrow \mathbb{C}$  viene dada por

$$\varphi_Y(t) = \int_{\mathbb{R}^d} e^{i\langle t, x \rangle} dF(x),$$

siendo  $\langle, \rangle$  un producto escalar en  $\mathbb{R}^d$ .

**Observación 2.2.** Como  $e^{itx} = \cos(tx) + i \sin(tx)$ , entonces

$$\varphi_X(t) = \int_{\mathbb{R}} \cos(tx) dF(x) + i \int_{\mathbb{R}} \sin(tx) dF(x).$$

Algunas propiedades de la función característica son

1.  $\varphi(0) = 1$ .
2.  $|\varphi(t)| \leq 1$  para todo  $t \in \mathbb{R}$ .

*Demostración.*

$$|\varphi(t)| = |E[e^{itX}]| \leq E[|e^{itX}|] = 1.$$

□

3.  $\varphi(-t) = \overline{\varphi(t)}$  para todo  $t \in \mathbb{R}$ .

*Demostración.*

$$\begin{aligned} \varphi(-t) &= E[e^{-itX}] = E[\cos(-tx) + i \sin(-tx)] = E[\cos(tx) - i \sin(tx)] \\ &= \overline{E[\cos(tx)] + i E[\sin(tx)]} = \overline{E[\cos(tx) + i \sin(tx)]} = \overline{\varphi(t)}. \end{aligned}$$

□

4.  $\varphi$  es una función definida positiva, es decir, para cada  $n \in \mathbb{N}$  y para cada  $z \in \mathbb{C}^n$ ,  $z = (z_1, \dots, z_n)$  se tiene que

$$\sum_{k,j=1}^n z_k \varphi(t_j - t_k) \overline{z_j} \geq 0.$$

*Demostración.*

$$\begin{aligned}
 \sum_{k,j=1}^n z_k \varphi(t_j - t_k) \overline{z_j} &= \sum_{k,j=1}^n z_k E \left[ e^{i(t_j - t_k)X} \right] \overline{z_j} = \sum_{k,j=1}^n z_k E \left[ e^{it_j X} e^{-it_k X} \right] \overline{z_j} \\
 &= E \left[ \sum_{k,j=1}^n z_k e^{it_j X} e^{-it_k X} \overline{z_j} \right] = E \left[ \sum_{k=1}^n z_k e^{-it_k X} \left( \sum_{j=1}^n \overline{z_j} e^{it_j X} \right) \right] \\
 &= E \left[ \sum_{k=1}^n z_k e^{-it_k X} \overline{\left( \sum_{j=1}^n z_j e^{-it_j X} \right)} \right] = E \left[ \left| \sum_{k=1}^n z_k e^{-it_k X} \right|^2 \right] \geq 0.
 \end{aligned}$$

□

**Teorema 2.3.**  $\varphi$  es uniformemente continua.

*Demostración.* Sean  $t, h \in \mathbb{R}$ , entonces

$$\begin{aligned}
 |\varphi(t+h) - \varphi(t)| &= \left| E \left[ e^{i(t+h)X} \right] - E \left[ e^{itX} \right] \right| = \left| E \left[ e^{i(t+h)X} - e^{itX} \right] \right| \\
 &= \left| E \left[ e^{itX} (e^{ihX} - 1) \right] \right| \leq E \left[ |e^{itX} (e^{ihX} - 1)| \right] \\
 &= E \left[ |e^{itX}| |e^{ihX} - 1| \right] = E \left[ |e^{ihX} - 1| \right]
 \end{aligned}$$

Como

- $|e^{ihX} - 1| \leq |e^{ihX}| + 1 = 2.$
- $|e^{ihX} - 1| \xrightarrow{h \rightarrow 0} 0.$

Por el Teorema de la Convergencia Dominada,  $E[e^{ihX} - 1] \xrightarrow{h \rightarrow 0} 0$ , de donde,  $|\varphi(t+h) - \varphi(t)| \xrightarrow{h \rightarrow 0} 0$  para cada  $t \in \mathbb{R}$ , lo que nos dice que  $\varphi$  es uniformemente continua. □

**Teorema 2.4** (de inversión). Sea  $X$  una variable aleatoria en  $(\Omega, \mathcal{A}, P)$  con función de distribución  $F$  y función característica  $\varphi$ . Dados  $a, b \in \mathbb{R}$ ,  $a < b$ , se tiene que

$$\frac{F(b) + F(b^-)}{2} - \frac{F(a) + F(a^-)}{2} = \lim_{T \rightarrow \infty} \int_{-T}^T \frac{e^{-itb} - e^{-ita}}{-it} \varphi(t) dt.$$

*Demostración.* Observamos que

$$\left| \frac{e^{-itb} - e^{-ita}}{-it} \right| = \left| \int_a^b e^{-itx} dx \right| \leq \int_a^b |e^{-itx}| = b - a < \infty.$$

Usando el Teorema de Fubini

$$\begin{aligned}
 \frac{1}{2\pi} \int_{-T}^T \frac{e^{-itb} - e^{-ita}}{-it} \varphi(t) dt &= \frac{1}{2\pi} \int_{-T}^T \frac{e^{-itb} - e^{-ita}}{-it} \left( \int_{-\infty}^{\infty} e^{itx} dF(x) \right) dt \\
 &= \frac{1}{\pi} \int_{-\infty}^{\infty} \int_{-T}^T \frac{e^{-it(x-a)} - e^{-it(x-b)}}{2it} dt dF(x).
 \end{aligned}$$

Llamemos

$$I(t) := \int_{-T}^T \frac{e^{-it(x-a)} - e^{-it(x-b)}}{2it} dt,$$

así

$$\begin{aligned}
 I(T) &= \int_{-T}^T \frac{\cos(t(x-a)) + i \operatorname{sen}(t(x-a)) - \cos(t(x-b)) - i \operatorname{sen}(t(x-b))}{2it} dt \\
 &= \int_0^T \frac{i2 \operatorname{sen}(t(x-a)) - i2 \operatorname{sen}(t(x-b))}{2it} dt = \int_0^T \left( \frac{\operatorname{sen}(t(x-a))}{t} - \frac{\operatorname{sen}(t(x-b))}{t} \right) dt.
 \end{aligned}$$



Definimos ahora la función

$$H(y) = \int_0^y \frac{\sin(t)}{t} dt,$$

que sabemos que verifica que  $H(-y) = H(y)$  y  $\lim_{y \rightarrow \infty} H(y) = \pi/2$ . Consideremos ahora el cambio de variables  $u = t(x - a)$ , de esta forma

$$\int_0^T \frac{\sin(t(x-a))}{t} dt = \int_0^{T(x-a)} \frac{\sin(u)}{u} du = H(T(x-a)) \xrightarrow{T \rightarrow \infty} \begin{cases} -\pi/2 & x < a \\ 0 & x = a \\ \pi/2 & x > a \end{cases}.$$

Actuando de igual forma para el cambio  $u = t(x - b)$ , llegamos a que

$$\lim_{T \rightarrow \infty} \int_0^T \left( \frac{\sin(t(x-a))}{t} - \frac{\sin(t(x-b))}{t} \right) dt = \begin{cases} 0 & x < a \\ \pi/2 & x = a \\ \pi & a < x < b \\ \pi/2 & x = b \\ 0 & x > b \end{cases}.$$

Entonces

$$\begin{aligned} \lim_{T \rightarrow \infty} \frac{1}{2\pi} \int_{-T}^T \frac{e^{-itb} - e^{-ita}}{-it} \varphi(b) dt &= \lim_{T \rightarrow \infty} \frac{1}{\pi} \int_{-\infty}^{\infty} I(t) dF(x) = \int_{-\infty}^{\infty} \lim_{T \rightarrow \infty} \frac{1}{\pi} I(t) dF(x) \\ &= \frac{1}{\pi} \left( \frac{\pi}{2} P(X = a) + \pi P(a < X < b) + \frac{\pi}{2} P(X = b) \right) \\ &= \frac{1}{\pi} \left( \frac{\pi}{2} (F(a) - F(a^-)) + \pi (F(b^-) - F(a)) + \frac{\pi}{2} (F(b) - F(b^-)) \right) \\ &= \frac{F(b) + F(b^-)}{2} - \frac{F(a) + F(a^-)}{2}. \end{aligned}$$

□

**Corolario 2.5.** Sea  $X$  una variable aleatoria en  $(\Omega, \mathcal{A}, P)$  con función de distribución  $F$  y función característica  $\varphi$ . Dados  $a, b \in C(F)$ ,  $a < b$ , se tiene que

$$F(b) - F(a) = \lim_{T \rightarrow \infty} \int_{-T}^T \frac{e^{-itb} - e^{-ita}}{-it} \varphi(t) dt.$$

**Teorema 2.6.** Sean  $X_1$  y  $X_2$  variables aleatorias con funciones de distribución  $F_1$  y  $F_2$  y funciones características  $\varphi_1$  y  $\varphi_2$  respectivamente. Entonces  $F_1 = F_2$  si y solo si  $\varphi_1 = \varphi_2$ .

*Demostración.*  $\Rightarrow$  Supongamos que  $F_1 = F_2$ , entonces

$$\varphi_1(t) = E[e^{itX_1}] = \int_{\mathbb{R}} e^{itx} dF_1(x) = \int_{\mathbb{R}} e^{itx} dF_2(x) = E[e^{itX_2}] = \varphi_2(t).$$

$\Leftarrow$  Supongamos que  $\varphi_1 = \varphi_2 \equiv \varphi$ . Sean  $a < b$ ,  $a, b \in C(F_1) \cap C(F_2)$ . Por el Teorema de Inversión

$$F_1(b) - F_1(a) = F_2(b) - F_2(a),$$

tomando límite  $a \rightarrow \infty$ , tenemos que

$$F_1(b) - 1 = F_2(b) - 1 \iff F_1(b) = F_2(b),$$

de donde deducimos que  $F_1$  y  $F_2$  coinciden en un denso de  $\mathbb{R}$  y por tanto,  $F_1 = F_2$  en todo  $\mathbb{R}$ . □

**Teorema 2.7.** Existe  $k \in (0, \infty)$  tal que para todo  $a > 0$  y toda medida de probabilidad  $P_F$  (puede ser cualquier medida de probabilidad arbitraria) tal que

$$P_F \left( \left[ -\frac{1}{a}, \frac{1}{a} \right]^c \right) \leq \frac{k}{a} \int_0^a (1 - \operatorname{Re} \varphi_F(t)) dt.$$

*Demostración.* Nótese que

$$\operatorname{Re}(\varphi_F(t)) = \operatorname{Re} E[e^{itX}] = \operatorname{Re} E[\cos(tx) + i \operatorname{sen}(tx)] = E[\cos(tx)],$$

de donde

$$1 - \operatorname{Re}(\varphi_F(t)) = E[1 - \cos(tx)].$$

Así,

$$\begin{aligned} \frac{1}{a} \int_0^a (1 - \operatorname{Re}(\varphi_F(t))) dt &= \frac{1}{a} \int_0^a \int_{\mathbb{R}} (1 - \cos(tx)) dF(x) dt = \int_{\mathbb{R}} \frac{1}{a} \int_0^a (1 - \cos(tx)) dt dF(x) \\ &= \int_{\mathbb{R}} \frac{1}{a} \left( \int_0^a 1 dt - \int_0^a \cos(tx) dt \right) dF(x) = \int_{\mathbb{R}} \left( 1 - \frac{\operatorname{sen}(ax)}{ax} \right) dF(x) \\ &\geq \int_{|ax| > 1} \left( 1 - \frac{\operatorname{sen}(ax)}{ax} \right) dF(x) \geq \inf_{|t| > 1} \left( 1 - \frac{\operatorname{sen}(t)}{t} \right) \cdot P_F \left( \left[ -\frac{1}{a}, \frac{1}{a} \right]^c \right) \end{aligned}$$

Basta tomar

$$k = \frac{1}{\inf_{|t| > 1} \left( 1 - \frac{\operatorname{sen}(t)}{t} \right)}$$

para obtener el resultado.  $\square$

**Corolario 2.8.** Sea  $\{X_n\}$  una sucesión de variables aleatorias, con  $F_n$ ,  $P_n$  y  $\varphi_n$  asociada a  $X_n$ . Supongamos que

1. Existe  $\delta > 0$  tal que  $\varphi_n \xrightarrow{n \rightarrow \infty} \varphi(t)$  para todo  $t \in [-\delta, \delta]$ .
2.  $\varphi$  es continua en 0.

Entonces  $\{X_n\}$  es ajustada, es decir,  $\{F_n\}$  forma una familia ajustada.

**Teorema 2.9.** Sea  $\{F_n\}$  una familia ajustada de funciones de distribución. Si todas las subsucesiones convergentes tienen el mismo límite  $F$ , entonces  $F_n \xrightarrow{d} F$ .

*Demostración.* Supongamos por reducción al absurdo que  $F_n \not\xrightarrow{d} F$ , entonces existe  $x \in C(F)$  tal que  $F_n(x) \not\rightarrow F(x)$ , es decir, existe una subsucesión  $\{F_{n_k}\}$  tal que  $F_{n_k}(x) \rightarrow \alpha \neq F(x)$ . Por hipótesis,  $\{F_{n_k}\}$  es ajustada, por el Teorema de Prokhorov, existe  $\{F_{n'_k}\} \subset \{F_{n_k}\}$  tal que  $F_{n'_k} \rightarrow F$  (por hipótesis). Como  $x \in C(F)$ , entonces  $F_{n'_k} \rightarrow F(x) \neq \alpha$ , lo que es una contradicción.  $\square$

**Teorema 2.10** (Continuidad de Levy). Sea  $\{X_n\}$  una sucesión de variables aleatorias con  $\varphi_n$  función característica asociada a  $X_n$ . Si existe  $\varphi$  función tal que

1.  $\varphi_n(t) \rightarrow \varphi(t)$  para todo  $t \in \mathbb{R}$ .
2.  $\varphi$  es continua en 0.

Entonces  $X_n \xrightarrow{d} X$ , donde  $X$  es la variable aleatoria con función característica  $\varphi$ .

*Demostración.* Por el Corolario ?? tenemos que  $\{X_n\}$  es una familia ajustada. Veamos que el límite de las subsucesiones de  $\{F_n\}$  es único, con lo que bastaría usar el Teorema ?? para llegar al resultado.

Sean  $\{F_{n_k}\}$  y  $\{F_{n_j}\}$  subsucesiones tales que

$$F_{n_k} \xrightarrow{d} G_1, \quad F_{n_j} \xrightarrow{d} G_2.$$

Consideremos las sucesiones asociadas de funciones características

$$\varphi_{n_k}(t) \rightarrow \varphi_{G_1}(t), \quad \varphi_{n_j}(t) \rightarrow \varphi_{G_2}(t)$$

para todo  $t \in \mathbb{R}$ . Como  $\{\varphi_{n_k}\}$  y  $\{\varphi_{n_j}\}$  son subsucesiones de  $\{\varphi_n\}$ , entonces, por hipótesis,  $\varphi_{G_1}(t) = \varphi_{G_2}(t) = \varphi(t)$  para todo  $t \in \mathbb{R}$ . De aquí, deducimos que

$$\int_{\mathbb{R}} e^{itx} dG_1(x) = \int_{\mathbb{R}} e^{itx} dG_2(x).$$

Como la función  $t \mapsto e^{itx}$ ,  $x \in \mathbb{R}$ , es continua y acotada, entonces esta igualdad implica que  $P_{G_1} = P_{G_2}$ . Por el Teorema de Correspondencia, tenemos que  $G_1 = G_2$ . Por el Teorema ??  $F_n \xrightarrow{d} F$ , es decir,  $X_n \xrightarrow{d} X$ .  $\square$

**Teorema 2.11.**  $\{F_n\}$  es ajustada si y solo si

$$\lim_{t \rightarrow 0} \left[ \limsup_{n \rightarrow \infty} \operatorname{Re}(1 - \varphi_n(t)) \right] = 0.$$

**Observación 2.12** (Teorema Central del Límite de De Moivre). Sea  $\{X_n\}$  una sucesión de variables aleatorias tales que  $X_n \sim Bi(n, p)$ . Tenemos entonces que  $E[X_n] = p$  y  $\operatorname{Var}[X_n] = npq$ , siendo  $q = 1 - p$ . Si definimos las variables aleatorias

$$Z_n = \frac{X_n - np}{\sqrt{npq}},$$

tenemos que  $Z_n \xrightarrow{d} Z$ , siendo  $Z \sim N(0, 1)$ .

*Demostración.*

$$\begin{aligned} \varphi_{Z_n}(t) &= E[e^{itZ_n}] = E\left[e^{it \frac{X_n - np}{\sqrt{npq}}}\right] = E\left[e^{it \frac{X_n}{\sqrt{npq}}} e^{-it \frac{np}{\sqrt{npq}}}\right] = e^{-it \frac{np}{\sqrt{npq}}} E\left[e^{it \frac{X_n}{\sqrt{npq}}}\right] \\ &= e^{-it \frac{np}{\sqrt{npq}}} \varphi_{X_n}\left(\frac{t}{\sqrt{npq}}\right). \end{aligned}$$

Como  $X_n \sim Bi(n, p)$ , entonces  $\varphi_{X_n}(t) = (pe^{-it} + q)^n$ . Por tanto,

$$\varphi_{Z_n}(t) = e^{-it \frac{np}{\sqrt{npq}}} \left( pe^{-i \frac{t}{\sqrt{npq}}} + q \right)^n = \left( pe^{i \frac{tq}{\sqrt{npq}}} + qe^{-i \frac{tp}{\sqrt{npq}}} \right)^n$$

Tomando límite cuando  $n \rightarrow \infty$ ,

$$\lim_{n \rightarrow \infty} \varphi_{Z_n}(t) = \lim_{n \rightarrow \infty} \left( pe^{i \frac{tq}{\sqrt{npq}}} + qe^{-i \frac{tp}{\sqrt{npq}}} \right)^n \implies \text{Indeterminación tipo "1}^\infty\text{"}$$

Recordemos que si

$$\lim_{x \rightarrow \infty} f(x) = 1, \quad \lim_{n \rightarrow \infty} g(x) = \infty,$$

entonces,

$$\lim_{x \rightarrow \infty} f(x)^{g(x)} = e^{\lim_{x \rightarrow \infty} g(x)(f(x)-1)}.$$

Usando esto, tenemos que

$$\lim_{n \rightarrow \infty} \varphi_{Z_n}(t) = \exp \left[ \lim_{n \rightarrow \infty} n \left( pe^{i \frac{tq}{\sqrt{npq}}} + qe^{-i \frac{tp}{\sqrt{npq}}} - 1 \right) \right].$$

Desarrollando la serie de Taylor de  $e^{i \frac{tq}{\sqrt{npq}}}$ :

$$e^{i \frac{tq}{\sqrt{npq}}} = \sum_{k=0}^{\infty} \frac{\left( i \frac{tq}{\sqrt{npq}} \right)^k}{k!} = 1 + i \frac{tq}{\sqrt{npq}} + \frac{\left( i \frac{tq}{\sqrt{npq}} \right)^2}{2!} + o\left( \frac{t^2}{npq} \right),$$

de donde,

$$\begin{aligned}
pe^{i\frac{tq}{\sqrt{npq}}} + qe^{-i\frac{tp}{\sqrt{npq}}} - 1 &= p \left[ 1 + i\frac{tq}{\sqrt{npq}} + \frac{\left(i\frac{tq}{\sqrt{npq}}\right)^2}{2!} \right] + q \left[ 1 - i\frac{tp}{\sqrt{npq}} + \frac{\left(-i\frac{tp}{\sqrt{npq}}\right)^2}{2!} \right] - 1 + o\left(\frac{t^2}{npq}\right) \\
&= p(iq)^2 \frac{t^2}{2npq} + q(ip)^2 \frac{t^2}{2npq} + o\left(\frac{t^2}{npq}\right) = -pq^2 \frac{t^2}{2npq} - qp^2 \frac{t^2}{2npq} + o\left(\frac{t^2}{npq}\right) \\
&= -\frac{t^2}{2npq} (pq^2 + qp^2) + o\left(\frac{t^2}{npq}\right) = -\frac{t^2}{2npq} pq + o\left(\frac{t^2}{npq}\right) \\
&= -\frac{t^2}{2n} + o\left(\frac{t^2}{npq}\right) = -\frac{t^2}{2n} + o\left(\frac{t^2}{n}\right).
\end{aligned}$$

Finalmente,

$$\begin{aligned}
\lim_{n \rightarrow \infty} \varphi_{Z_n}(t) &= \exp \left[ \lim_{n \rightarrow \infty} n \left( pe^{i\frac{tq}{\sqrt{npq}}} + qe^{-i\frac{tp}{\sqrt{npq}}} - 1 \right) \right] = \exp \left[ \lim_{n \rightarrow \infty} n \left( -\frac{t^2}{2n} + o\left(\frac{t^2}{n}\right) \right) \right] \\
&= e^{-t^2/2} = \varphi_Z(t),
\end{aligned}$$

siendo  $Z \sim N(0, 1)$ . Por el Teorema de Levy,  $Z_n \xrightarrow{d} Z$ ,  $Z \sim N(0, 1)$ .  $\square$

**Proposición 2.13.** Si  $E[|X|^n] < \infty$  para cierto  $n \geq 1$ , entonces existen y son finitos  $E[X^r]$  para cada  $1 \leq r \leq n$ .

**Definición 2.14.** El espacio  $L^r$  es el conjunto de las variables aleatorias  $X$  tales que  $E[|X|^r] < \infty$ , es decir,

$$L^r = \left\{ X \text{ variable aleatoria} : \int_{\mathbb{R}} |x|^r dF(x) < \infty \right\}.$$

**Teorema 2.15.** Sea  $X \in L^n$ , para cierto  $n \geq 1$ , con función característica  $\varphi$ . Entonces existen las derivadas  $\varphi^{(k)}$  para  $k = 1, \dots, n$ , son uniformemente continuas y

$$\varphi^{(k)}(t) = i^k \int_{\mathbb{R}} x^k e^{itx} dF(x).$$

Además,

$$\varphi^{(k)}(0) = i^k E[X^k],$$

y

$$\varphi(t) = 1 + \sum_{k=1}^n \frac{(it)^k}{k!} E[X^k] + o(t^n).$$

**Proposición 2.16.** Sean  $X$  e  $Y$  variables aleatorias independientes con funciones características  $\varphi_X$  y  $\varphi_Y$  respectivamente. Entonces la función característica de la variable aleatoria  $S = X + Y$  es  $\varphi_S(t) = \varphi_X(t) \cdot \varphi_Y(t)$ .

**Observación 2.17.** En general, si  $X_1, \dots, X_n$  son variables aleatorias independientes y  $S = X_1 + \dots + X_n$ , entonces

$$\varphi_S(t) = \prod_{i=1}^n \varphi_{X_i}(t).$$

**Lema 2.18.**

$$\left| e^{it} - \sum_{k=0}^n \frac{(iy)^k}{k!} \right| \leq \min \left\{ \frac{2|y|^n}{n!}, \frac{|y|^{n+1}}{(n+1)!} \right\}.$$

**Teorema 2.19.** Si  $\varphi$  es absolutamente integrable, entonces  $F$  es absolutamente continua y su función de densidad es

$$f(x) = \frac{1}{2\pi} \int_{\mathbb{R}} e^{itx} \varphi(t) dt.$$

**Lema 2.20** (Riemann-Lebesgue). Si  $F$  es absolutamente continua entonces

$$\lim_{t \rightarrow \infty} |\varphi(t)| = 0, \quad \lim_{t \rightarrow -\infty} |\varphi(t)| = 0.$$

**Lema 2.21.**

$$P(X = a) = \lim_{T \rightarrow \infty} \frac{1}{2T} \int_{-T}^T e^{-ita} \varphi(t) dt.$$

## 2.2. Función generatriz de momentos y Función generatriz de cumulantes

**Definición 2.22.** Sea  $X$  una variable aleatoria con función característica  $\varphi$ , se define la función generatriz de cumulantes de  $X$  como  $\kappa : \mathbb{R} \rightarrow \mathbb{C}$  dada por

$$\kappa(t) = \log \varphi(t).$$

**Proposición 2.23.** Sean  $X_1, \dots, X_n$  variables aleatorias independientes con funciones características  $\varphi_1, \dots, \varphi_n$  respectivamente. Sea  $S = X_1 + \dots + X_n$ , entonces

$$\kappa_S(t) = \sum_{i=1}^n \kappa_{X_i}(t).$$

**Teorema 2.24.** Si  $E[|X|^n] < \infty$  para cierto  $n \geq 1$ . Entonces

$$\kappa(t) = \sum_{j=0}^n \frac{(it)^j}{j!} C_j + o(t^n),$$

siendo

$$C_j = \frac{\kappa^{(j)}(0)}{i^j}.$$

$C_j$  se conoce como el cumulante de orden  $j$ .

**Observación 2.25.**  $C_1 = E[X]$  y  $C_2 = \text{Var}[X]$ .

**Observación 2.26.** Si  $X \sim N(\mu, \sigma^2)$ , entonces  $C_1 = \mu$ ,  $C_2 = \sigma^2$  y  $C_n = 0$  para todo  $n \geq 3$ .

**Definición 2.27.** Sea  $X$  una variable aleatoria con  $\sigma = \sqrt{\text{Var}[X]}$ . Se definen

- Sesgo:  $C_3/\sigma^3$ .
- Curtosis:  $C_4/\sigma^4$ .

**Definición 2.28.** Sea  $X$  una variable aleatoria con función característica  $\varphi$ , se define la función generatriz de momentos de  $X$  como

$$\psi(t) = E[e^{tX}] = \int_{\mathbb{R}} e^{tx} dF(x),$$

siempre que exista  $h > 0$  tal que  $\psi$  esté definida para todo  $|t| < h$ .

**Observación 2.29.** Si existe  $\psi$ , entonces  $E[|X|^n] < \infty$  para todo  $n \in \mathbb{N}$ .

**Definición 2.30.** Sea  $X$  una variable aleatoria que toma valores en  $\mathbb{Z}_+ = \{0, 1, 2, \dots\}$ . La función generatriz de probabilidad de  $X$  es

$$G_X(t) = E[t^X] = \sum_{n=0}^{\infty} t^n P(X = n), \quad |t| < 1.$$

**Observación 2.31.**

$$G_X^{(k)}(t) = \sum_{n=k}^{\infty} n(n-1)\dots(n-k+1)t^{n-k}P(X = n)$$

$$G_X^{(k)}(0) = k!P(X = k) \implies P(X = K) = \frac{G_X^{(K)}(0)}{k!}.$$

**Observación 2.32.** Sea  $X = Y_1 + \dots + Y_N$ , siendo  $Y_i$  variables aleatorias independientes e igualmente distribuidas y  $N$  una variable aleatoria en  $\mathbb{Z}_+$ . Entonces  $X$  sigue una distribución compuesta y su función característica es

$$\begin{aligned} \varphi_X(t) &= E[e^{itX}] = E[E[e^{itX}|N]] = \sum_{n=0}^{\infty} E[e^{itX}|N = n] P(N = n) \\ &= \sum_{n=0}^{\infty} E[e^{it \sum_{i=1}^n Y_i} | N = n] P(N = n) = \sum_{n=0}^{\infty} (\varphi_Y(t))^n P(N = n) \\ &= G_N(\varphi_Y(t)) \end{aligned}$$

**Lema 2.33.** Sean  $\mu_1, \dots, \mu_n$  medidas de probabilidad con funciones características  $\varphi_1, \dots, \varphi_n$  respectivamente. Sean  $\alpha_1, \dots, \alpha_n \in [0, 1]$  tales que  $\sum_{i=1}^n \alpha_i = 1$ . Entonces, la función característica asociada a la medida de probabilidad  $\sum_{i=1}^n \alpha_i \mu_i$  es  $\sum_{i=1}^n \alpha_i \varphi_i$ .

*Demostración.*

$$\varphi(t) = \int_{\mathbb{R}} e^{itx} d(\alpha_1 \mu_1 + \dots + \alpha_n \mu_n) = \alpha_1 \int_{\mathbb{R}} e^{itx} d\mu_1 + \dots + \alpha_n \int_{\mathbb{R}} e^{itx} d\mu_n$$

□

**Definición 2.34.** Una función  $g : \mathbb{R} \longrightarrow \mathbb{C}$  es definida positiva si

$$\sum_{j=1}^n \sum_{i=1}^n g(t_j - t_i) z_j \overline{z_k} \geq 0,$$

para cualesquiera  $t_1, \dots, t_n \in \mathbb{R}$  y cualesquiera  $z_1, \dots, z_n \in \mathbb{C}$ .

**Observación 2.35.** La función característica es definida positiva (se probó al inicio de este mismo capítulo).

**Teorema 2.36.** Si  $g$  es definida positiva y continua en 0, entonces  $g$  es uniformemente continua en  $\mathbb{R}$ .

**Lema 2.37** (Herglotz). Si  $\phi : \mathbb{Z} \longrightarrow \mathbb{C}$  es definida positiva y  $\phi(0) = 1$ , entonces existe  $\mu$  distribución de probabilidad en  $[-\pi, \pi]$  tal que  $\phi$  es su función característica asociada, es decir,

$$\phi(t) = \int_{-\pi}^{\pi} e^{itx} d\mu,$$

para todo  $t \in \mathbb{Z}$ .

**Teorema 2.38** (Bochner). Sea  $\varphi : \mathbb{R} \longrightarrow \mathbb{C}$  verificando:

(i) es definida positiva,

(ii) continua en 0,

(iii)  $\varphi(0) = 1$ .

Entonces,  $\varphi$  es función característica.

**Corolario 2.39.** Toda combinación lineal convexa de funciones características es función característica.

**Proposición 2.40.** La función  $\varphi_T$  dada por

$$\varphi_T(t) = \max \left\{ 1 - \frac{|t|}{T}, 0 \right\} \equiv \begin{cases} 1 - \frac{|t|}{T}, & |t| \leq T, \\ 0, & |t| > T \end{cases}, \quad T \in \mathbb{R},$$

es función característica.

**Lema 2.41.** Sea  $\varphi : \mathbb{R} \rightarrow \mathbb{R}$  tal que  $\varphi(0) = 1$ , no negativa, par y  $\varphi$  es una poligonal convexa no creciente en  $\mathbb{R}^+$ . Entonces  $\varphi$  es función característica.

**Teorema 2.42** (Criterio de Pólya). Sea  $\varphi : \mathbb{R} \rightarrow \mathbb{R}$  tal que:

(i)  $\varphi(0) = 1$ ,

(ii)  $\varphi$  no negativa, par y continua.

(iii)  $\varphi$  convexa y no creciente en  $\mathbb{R}^+$ .

Entonces  $\varphi$  es función característica.





## Capítulo 3

# Convergencia

Consideremos un espacio de probabilidad  $(\Omega, \mathcal{A}, P)$ ,  $P : \mathcal{A} \rightarrow [0, 1]$ . Sean  $A_1, \dots, A_n \in \mathcal{A}$  una sucesión de sucesos. Definimos el límite inferior y superior como sigue

$$\liminf_n A_n = \bigcup_{n \geq 1} \bigcap_{m \geq n} A_m \in \mathcal{A}, \quad \limsup_n A_n = \bigcap_{n \geq 1} \bigcup_{m \geq n} A_m \in \mathcal{A}.$$

Decimos que la sucesión  $\{A_n\}$  converge si  $\liminf_n A_n = \limsup_n A_n$ . Algunos resultados que ya conocemos son los siguientes:

- Toda sucesión monótona es convergente.
- Si  $\{A_n\}$  es monótona creciente, entonces  $\lim_n A_n = \cup_{i \geq 1} A_i$ .
- Si  $\{A_n\}$  es monótona decreciente, entonces  $\lim_n A_n = \cap_{i \geq 1} A_i$ .

**Teorema 3.1.** Sea  $(\Omega, \mathcal{A}, P)$  un espacio de probabilidad y consideremos  $\{A_n\} \subset \mathcal{A}$  una sucesión monótona creciente. Entonces

$$P\left(\lim_n A_n\right) = \lim_n P(A_n).$$

*Demostración.* Como  $\{A_n\}$  es creciente, entonces  $\lim_n A_n = \cup_{i \geq 1} A_i$ , de donde:

$$P\left(\lim_n A_n\right) = P\left(\bigcup_{i \geq 1} A_i\right).$$

Como los  $A_n$  no son disjuntos, definimos  $F_n = A_n \setminus A_{n-1}$  para cada  $n \geq 2$ . Es claro que los  $F_n$  son disjuntos y que

$$\bigcup_{i \geq 1} A_i = A_1 \dot{\cup} F_2 \dot{\cup} \dots \dot{\cup} F_n \dot{\cup} \dots$$

De aquí,

$$\begin{aligned} P\left(\bigcup_{i \geq 1} A_i\right) &= P(A_1) + P(F_2) + \dots + P(F_n) + \dots = P(A_1) + \lim_{n \rightarrow \infty} \sum_{i=2}^n P(F_i) \\ &= P(A_1) + \lim_{n \rightarrow \infty} (P(A_n) - P(A_1)) = \lim_{n \rightarrow \infty} P(A_n). \end{aligned}$$

□

**Teorema 3.2.** Sea  $(\Omega, \mathcal{A}, P)$  un espacio de probabilidad y consideremos  $\{A_n\} \subset \mathcal{A}$  una sucesión monótona decreciente. Entonces

$$P\left(\lim_n A_n\right) = \lim_n P(A_n).$$

*Demostración.* Consideramos  $\{A_n^c\}$ , que es una sucesión monótona decreciente. Por el Teorema anterior

$$P\left(\bigcup_{i \geq 1} A_i^c\right) = P\left(\lim_n A_n^c\right) = \lim_n P(A_n^c).$$

Por las leyes de De Morgan:

$$P\left(\bigcup_{i \geq 1} A_i^c\right) = P\left(\left(\bigcap_{i \geq 1} A_i\right)^c\right) = 1 - P\left(\bigcap_{i \geq 1} A_i\right)$$

Así,

$$\lim_{n \rightarrow \infty} P(A_n^c) = \lim_{n \rightarrow \infty} (1 - P(A_n)) = 1 - P\left(\bigcap_{i \geq 1} A_i\right) \Rightarrow \lim_{n \rightarrow \infty} P(A_n) = P\left(\bigcap_{i \geq 1} A_i\right)$$

□

**Teorema 3.3.** Sea  $(\Omega, \mathcal{A}, P)$  un espacio de probabilidad y consideremos  $\{A_n\} \subset \mathcal{A}$  una sucesión. Entonces

$$P\left(\limsup_n A_n\right) = \lim_n P\left(\bigcup_{m \geq n} A_m\right).$$

*Demostración.* Como  $\limsup_n A_n = \bigcap_{n \geq 1} \bigcup_{m \geq n} A_m$ , tenemos que  $\{\bigcup_{m \geq n} A_m\}$  es una sucesión decreciente y

$$\bigcap_{n \geq 1} \bigcup_{m \geq n} A_m = \lim_{n \rightarrow \infty} \left(\bigcup_{m \geq n} A_m\right),$$

de donde concluimos que

$$P\left(\limsup_n A_n\right) = P\left(\bigcap_{n \geq 1} \bigcup_{m \geq n} A_m\right) = P\left(\lim_{n \rightarrow \infty} \left(\bigcup_{m \geq n} A_m\right)\right) = \lim_{n \rightarrow \infty} P\left(\bigcup_{m \geq n} A_m\right).$$

□

**Teorema 3.4.** Sea  $(\Omega, \mathcal{A}, P)$  un espacio de probabilidad y consideremos  $\{A_n\} \subset \mathcal{A}$  una sucesión. Entonces

$$P\left(\liminf_n A_n\right) = \lim_n P\left(\bigcap_{m \geq n} A_m\right).$$

**Teorema 3.5.** Sea  $(\Omega, \mathcal{A}, P)$  un espacio de probabilidad y consideremos  $\{A_n\} \subset \mathcal{A}$  una sucesión. Sea  $\omega \in \Omega$ , entonces  $\omega \in \limsup_n A_n$  si y solo si existe una sucesión de índices  $n_1 < n_2 < \dots < n_k < \dots$  tal que  $\omega \in A_{n_k}$  para todo  $k \in \mathbb{N}$ .

*Demostración.*  $\Rightarrow$  Supongamos que  $\omega \in \limsup A_n$ , es decir,

$$\omega \in \bigcap_{n \geq 1} \bigcup_{m \geq n} A_m.$$

En particular,  $\omega \in \bigcup_{m \geq 1} A_m$ , es decir, existe  $\xi \in \mathbb{N}$ , tal que  $\omega \in A_\xi$ . Tomamos  $n_1 = \xi$ . Por inducción sobre  $k$ , suponemos que  $\omega \in A_{n_i}$ ,  $i = 1, \dots, k$ . Actuando de igual forma,  $\omega \in \bigcup_{m \geq n_{k+1}} A_m$ , es decir,

existe  $\xi' \in \mathbb{N}$  tal que  $\omega \in A_{\xi'}$  y tomamos  $n_{k+1} = \xi'$ .

◀ Por reducción al absurdo, supongamos que existe una sucesión de índices  $n_1 < n_2 < \dots < n_k < \dots$  tal que  $\omega \in A_{n_k}$  para todo  $k \in \mathbb{N}$  y que  $\omega \notin \limsup A_n$ . De esto últimos, tenemos que

$$\omega \notin \bigcap_{n \geq 1} \bigcup_{m \geq n} A_m \implies \omega \in \left( \bigcap_{n \geq 1} \bigcup_{m \geq n} A_m \right)^c \implies \omega \in \bigcup_{n \geq 1} \bigcap_{m \geq n} A_m^c,$$

es decir, existe  $n_0 \in \mathbb{N}$  (fijo) tal que  $\omega \in A_m^c$  para todo  $m \geq n_0$ , es decir,  $\omega \in A_m$  para todo  $m \geq n_0$ , lo que nos dice que  $\omega$  está en un número finito de  $A_n$ , los que es una contradicción.  $\square$

**Teorema 3.6.** Sea  $(\Omega, \mathcal{A}, P)$  un espacio de probabilidad y consideremos  $\{A_n\} \subset \mathcal{A}$  una sucesión. Sea  $\omega \in \Omega$ , entonces  $\omega \in \liminf_n A_n$  si y solo si existe  $n_0 \in \mathbb{N}$  tal que  $\omega \in A_m$  para todo  $m \geq n_0$ .

**Teorema 3.7** (Primer Lema de Borel-Cantelli). Sea  $(\Omega, \mathcal{A}, P)$  un espacio de probabilidad y consideremos  $\{A_n\} \subset \mathcal{A}$  una sucesión tal que  $\sum_{n \geq 1} P(A_n) < \infty$ . Entonces

$$P\left(\limsup_n A_n\right) = 0.$$

*Demostración.*

$$\begin{aligned} P\left(\limsup_n A_n\right) &= P\left(\bigcap_{n \geq 1} \bigcup_{m \geq n} A_m\right) \stackrel{(*)}{=} P\left(\lim_{n \rightarrow \infty} \bigcup_{m \geq n} A_m\right) \\ &= \lim_{n \rightarrow \infty} P\left(\bigcup_{m \geq n} A_m\right) \leq \lim_{n \rightarrow \infty} \sum_{m \geq n} P(A_m) = 0. \end{aligned}$$

En  $(*)$  estamos usando que la sucesión  $\{\bigcup_{m \geq n} A_m\}$  es decreciente.  $\square$

**Teorema 3.8** (Segundo Lema de Borel-Cantelli). Sea  $(\Omega, \mathcal{A}, P)$  un espacio de probabilidad y consideremos  $\{A_n\} \subset \mathcal{A}$  una sucesión tal que  $\sum_{n \geq 1} P(A_n) = \infty$ . Entonces

$$P\left(\limsup_n A_n\right) = 1.$$

*Demostración.*

$$\begin{aligned} P\left(\limsup_n A_n\right) &= P\left(\bigcap_{n \geq 1} \bigcup_{m \geq n} A_m\right) = 1 - P\left[\left(\bigcap_{n \geq 1} \bigcup_{m \geq n} A_m\right)^c\right] \\ &= 1 - P\left(\bigcup_{n \geq 1} \bigcap_{m \geq n} A_m^c\right) = 1 - P\left(\lim_{n \rightarrow \infty} \bigcap_{m \geq n} A_m^c\right) \\ &= 1 - \lim_{n \rightarrow \infty} P\left(\bigcap_{m \geq n} A_m^c\right) = 1 - \lim_{n \rightarrow \infty} \prod_{m \geq n} P(A_m^c) \\ &= 1 - \lim_{n \rightarrow \infty} \prod_{m \geq n} (1 - P(A_m)). \end{aligned}$$

Observamos que

$$\prod_{m \geq n} (1 - P(A_m)) \stackrel{(*)}{=} \prod_{m \geq n} e^{-P(A_m)} = e^{-\sum_{m \geq n} P(A_m)} = 0.$$

En  $(*)$  usamos que si  $x \geq 0$ , entonces  $1 - x \leq e^{-x}$ . Finalmente, gracias a lo anterior

$$P\left(\limsup_n A_n\right) = 1.$$

$\square$

**Corolario 3.9** (Ley 0-1 de Borel-Cantelli). Sea  $(\Omega, \mathcal{A}, P)$  un espacio de probabilidad y consideremos  $\{A_n\} \subset \mathcal{A}$  una sucesión de sucesos independientes, entonces  $P(\limsup_n A_n)$  o bien es 0, o bien es 1.

Sean  $X_n$  variables aleatorias en  $(\Omega, \mathcal{A}, P)$ . Definimos

$$\Omega_1 = \{\omega \in \Omega : \liminf_n X_n(\omega) = \limsup_n X_n(\omega)\},$$

que es el conjunto de  $\omega \in \Omega$  para los cuales existe  $\lim_n X_n$ .

**Teorema 3.10.** Sean  $X_i$  variables aleatorias en  $(\Omega, \mathcal{A}, P)$ . Entonces  $\inf_n X_n$ ,  $\sup_n X_n$ ,  $\liminf_n X_n$  y  $\limsup_n X_n$  son variables aleatorias.

*Demostración.* Sea  $Y = \inf_n X_n$  y fijemos  $b \in \mathbb{R}$ . Entonces

$$\begin{aligned} Y^{-1}((-\infty, b)) &= \left\{ \omega \in \Omega : \inf_n X_n(\omega) < b \right\} = \bigcup_{n \geq 1} \{\omega \in \Omega : X_n(\omega) < b\} \\ \bigcup_{n \geq 1} X_n^{-1}((-\infty, b)) &\in \mathcal{A}, \end{aligned}$$

es decir,  $Y$  es variable aleatoria. Observamos que  $\sup_n X_n = -\inf_n (-X_n)$ ,  $\liminf_n X_n = \sup_n \inf_{m \geq n} X_m$  y  $\limsup_n X_n = \inf_n \sup_{m \geq n} X_m$ . Aplicar una función medible a una variable aleatoria, nos sigue dando una variable aleatoria, por tanto, todo lo anterior eran variables aleatorias.  $\square$

**Corolario 3.11.**  $\Omega_1$  es medible.

**Definición 3.12.** Sea  $\{X_n\}$  una sucesión de variables aleatorias en  $(\Omega, \mathcal{A}, P)$ . Decimos que  $X_n$  converge casi seguro si  $P(\Omega_1) = 1$ . En tal caso,  $X := \lim_n X_n$  y  $X_n \xrightarrow{c.s.} X$ .

**Teorema 3.13.**  $X_n \xrightarrow{c.s.} X$  si y solo si  $P(\liminf_n y_{n,k}) = 1$  para todo  $k$ , siendo

$$y_{n,k} = \left\{ \omega \in \Omega : |X_n(\omega) - X(\omega)| < \frac{1}{k} \right\}.$$

**Teorema 3.14.**  $X_n \xrightarrow{c.s.} X$  si y solo si  $P(\limsup_n y_{n,k}^c) = 0$  para todo  $k$ .

**Definición 3.15.** Diremos que  $X_n$  converge en probabilidad a  $X$  si para todo  $\varepsilon > 0$

$$P(y_{n,\varepsilon}) \xrightarrow{n \rightarrow \infty} 1,$$

siendo

$$y_{n,\varepsilon} = \{\omega \in \Omega : |X_n(\omega) - X(\omega)| < \varepsilon\}.$$

**Teorema 3.16.** El límite en probabilidad es único casi seguro (c.s.).

**Teorema 3.17.** Si  $X_n \xrightarrow{c.s.} X$ , entonces  $X_n \xrightarrow{p} X$ .

**Teorema 3.18.** Si  $X_n \xrightarrow{p} X$ , entonces existe alguna subsucesión  $X_{n_k}$  de  $X$  tal que  $X_{n_k} \xrightarrow{c.s.} X$ .

**Teorema 3.19.**  $X_n \xrightarrow{p} X$  si y solo si toda subsucesión contiene una subsucesión convergente casi seguro.

**Teorema 3.20.** La convergencia en probabilidad implica la convergencia en distribución.

**Teorema 3.21.** Sean  $X_n, X$  variables aleatorias en  $(\Omega, \mathcal{A}, P)$  con  $X \sim \delta(c)$ ,  $c$  constante. Entonces  $X_n \xrightarrow{p} X$  si y solo si  $X_n \xrightarrow{d} X$ .

---

Consideremos el espacio

$$L^p(\Omega, \mathcal{A}, P) = \{X \text{ v.a} : E[|X|^p] < \infty\}.$$

Se puede probar que  $(L^p, \|\cdot\|_p)$  es un espacio métrico, siendo

$$\|X\|_p = \left( \int_{\Omega} |X|^p dP \right)^{1/p}$$

**Definición 3.22.** Diremos que  $X_n$  converge a  $X$  en  $L^p$ ,  $X_n \xrightarrow{L^p} X$ , cuando  $\|X_n - X\|_p \xrightarrow{n \rightarrow \infty} 0$ .

Diremos que

- Converge en media si  $p = 1$ .
- Converge en media cuadrática si  $p = 2$ .

Desigualdad de Markov: Sea  $X$  variable no negativa y  $a > 0$ , entonces

$$P(X \geq a) \leq \frac{E[X]}{a}.$$

Si además  $X \in L^p$

$$P(X \geq a) \leq \frac{E[X^p]}{a^p}.$$

**Teorema 3.23.**  $X_n, X \in L^p$ . Si  $X_n \xrightarrow{L^p} X$ , entonces  $X_n \xrightarrow{p} X$ .

**Teorema 3.24.** El límite en  $L^p$  es único.

**Teorema 3.25.** Sean  $X_n, X \in L^p$  tales que  $X_n \xrightarrow{p} X$ . Si existe  $Y \in L^p$  tal que  $|X_n| \leq Y$  para todo  $n$ , entonces  $X_n \xrightarrow{L^p} X$ .

### Ley débil de los grandes números (LDGN)

Sean  $X_1, X_2, \dots$  variables aleatorias en  $(\Omega, \mathcal{A}, P)$ . Definimos

$$S_n = X_1 + \dots + X_n, \quad n \geq 1.$$

La sucesión  $\{X_n\}$  verifica la ley débil de los grandes números si existen sucesiones numéricas  $\{a_n\}$  y  $\{b_n\}$  con  $b_n \uparrow \infty$  tales que

$$\frac{S_n - a_n}{b_n} \xrightarrow{p} 0.$$

**Teorema 3.26** (Bernoulli, 1713). Sean  $X_1, X_2, \dots$  variables aleatorias independientes en  $(\Omega, \mathcal{A}, P)$  con  $X_i \sim \text{Ber}(p)$ ,  $0 < p < 1$ . Entonces

$$\frac{S_n}{n} \xrightarrow{p} p,$$

es decir, verifica LDGN para  $a_n = np$  y  $b_n = n$ .

**Teorema 3.27** (Chebyshev). Sea  $\{X_n\}$  una sucesión de variables aleatorias independientes con media  $\mu$  y varianza  $\sigma^2$  constantes. Entonces

$$\frac{S_n}{n} \xrightarrow{p} \mu$$

**Teorema 3.28** (Chebyshev). Sea  $\{X_n\}$  una sucesión de variables aleatorias independientes con varianza acotada por una constante. Entonces

$$\frac{S_n - E[S_n]}{n} \xrightarrow{p} 0$$

**Teorema 3.29** (Markov). Sea  $\{X_n\}$  una sucesión de variables aleatorias independientes tal que  $\text{Var}[S_n/n] \xrightarrow{n \rightarrow \infty} 0$ . Entonces

$$\frac{S_n - E[S_n]}{n} \xrightarrow{p} 0$$

**Teorema 3.30** (Khinchin). Sea  $\{X_n\}$  una sucesión de variables aleatorias independientes e idénticamente distribuidas con media  $\mu$  finita. Entonces

$$\frac{S_n}{n} \xrightarrow{p} \mu$$

### Ley fuerte de los grandes números (LFGN)

Sean  $X_1, X_2, \dots$  variables aleatorias en  $(\Omega, \mathcal{A}, P)$ . La sucesión  $\{X_n\}$  verifica la ley fuerte de los grandes números si existen sucesiones numéricas  $\{a_n\}$  y  $\{b_n\}$  con  $b_n \uparrow \infty$  tales que

$$\frac{S_n - a_n}{b_n} \xrightarrow{c.s.} 0.$$

**Lema 3.31.** Sea  $\{X_n\}$  sucesión de variables aleatorias. Entonces  $\sum_{n=1}^{\infty} X_n$  converge casi seguro si y solo si

$$\lim_{n \rightarrow \infty} \lim_{m \rightarrow \infty} P\left(\max_{1 \leq j \leq m} |S_j - S_m| \geq \varepsilon\right) = 0$$

para todo  $\varepsilon > 0$ .

**Teorema 3.32** (Criterio de convergencia de Kolmogórov). Sea  $\{X_n\}$  una sucesión de variables aleatorias independientes con  $\sum_{n=1}^{\infty} \text{Var}[X_n] < \infty$ . Entonces  $\sum_{n=1}^{\infty} (X_n - E[X_n]) < \infty$  c.s.

**Teorema 3.33** (Recíproco de Kolmogórov). Sea  $\{X_n\}$  una sucesión de variables aleatorias independientes. Si existe una constante  $c > 0$  tal que  $|X_n| < c$  c.s para todo  $n$ . Entonces

$$\sum_{n=1}^{\infty} (X_n - E[X_n]) < \infty \text{ c.s} \iff \sum_{n=1}^{\infty} \text{Var}[X_n] < \infty.$$

**Corolario 3.34.** Sea  $\{X_n\}$  una sucesión de variables aleatorias tales que  $|X_n| < c$  c.s para algún  $c > 0$  constante. Si  $\sum_{n=1}^{\infty} X_n < \infty$  c.s, entonces también convergen las series  $\sum_{n=1}^{\infty} (X_n - E[X_n])$  c.s,  $\sum_{n=1}^{\infty} E[X_n]$  y  $\sum_{n=1}^{\infty} \text{Var}[X_n]$ .

**Teorema 3.35** (Condición suficiente de Kolmogórov). Sea  $\{X_n\}$  una sucesión de variables aleatorias independientes con varianza finita. Si  $\sum_{n=1}^{\infty} \frac{\text{Var}[X_n]}{n^2} < \infty$ , entonces  $\{X_n\}$  verifica la ley fuerte de los grandes números, es decir,

$$\frac{S_n}{n} \xrightarrow{c.s.} 0$$

**Lema 3.36** (Kronecker). Sea  $\{X_n\}$  una sucesión de variables aleatorias y  $\{a_n\}$  una sucesión de números reales tal que  $a_n \uparrow \infty$ . Si  $\sum_{n=1}^{\infty} \frac{X_n}{a_n} < \infty$  c.s, entonces  $\frac{1}{a_n} \sum_{k=1}^n X_k \xrightarrow[n \rightarrow \infty]{c.s.} 0$ .

**Definición 3.37.** Sean  $\{X_n\}$  una sucesión de variables aleatorias y  $\{c_n\}$  una sucesión de números reales no negativos. Se define la sucesión de variables aleatorias truncadas como  $\{Y_n\}$  donde

$$Y_n = X_n \mathbb{1}_{\{|X_n| < c_n\}}.$$

**Definición 3.38.** Dos sucesiones de variables aleatorias  $\{X_n\}$  e  $\{Y_n\}$  son equivalentes en convergencia cuando  $\sum_{n=1}^{\infty} P(X_n \neq Y_n) = 0$ .

**Teorema 3.39.** Si  $\{X_n\}$  e  $\{Y_n\}$  son equivalentes en convergencia, entonces

- 
1.  $P(\limsup_n \{X_n \neq Y_n\}) = 0$ .
  2.  $\sum_{n=1}^{\infty} X_n < \infty$  c.s si y solo si  $\sum_{n=1}^{\infty} Y_n < \infty$  c.s.
  3.  $\frac{1}{n} \sum_{k=1}^n (X_k - Y_k) < \infty \xrightarrow[n \rightarrow \infty]{c.s} 0$ .

**Teorema 3.40** (3 series de Kolmogórov). Sean  $\{X_n\}$  una sucesión de variables aleatorias independientes y  $\{X_n^c\}$  una sucesión de variables aleatorias  $X_n$  truncadas, para alguna constante  $c > 0$ . Si existe  $c > 0$  tal que las series  $\sum_{n=1}^{\infty} P(X_n \neq X_n^c)$ ,  $\sum_{n=1}^{\infty} E[X_n^c]$  y  $\sum_{n=1}^{\infty} \text{Var}[X_n^c]$  convergen, entonces  $\sum_{n=1}^{\infty} X_n$  converge c.s.

Recíprocamente, si  $\sum_{n=1}^{\infty} X_n$  converge c.s, entonces las tres series convergen para todo  $c > 0$ .

**Lema 3.41.** Sea  $X$  una variable aleatoria. Se tiene que  $E[|X|] < \infty$  si y solo si  $\sum_{n=1}^{\infty} P(|X| \geq n) < \infty$ .

**Teorema 3.42** (Ley fuerte de los grandes números). Sean  $X_1, X_2, \dots$  variables aleatorias independientes e igualmente distribuidas con  $E[X_1] = \mu < \infty$ , entonces

$$\frac{S_n}{n} \xrightarrow[n]{c.s} \mu.$$

Recíprocamente, si  $\frac{S_n}{n} \xrightarrow[n]{c.s} c$  (constante), entonces  $E[X_1] = c$ .

**Teorema 3.43** (Teorema central del límite). Sean  $X_1, X_2, \dots$  variables aleatorias, independientes e idénticamente distribuidas con  $E[X_1] = \mu < \infty$  y  $\text{Var}[X_1] = \sigma^2 < \infty$ . Entonces

$$\frac{\sqrt{n}}{\sigma} \left( \frac{S_n}{n} - \mu \right) \xrightarrow{d} Z \sim N(0, 1).$$

**Teorema 3.44** (TCL de Lindeberg-Feller). Sean  $X_1, X_2, \dots$  variables aleatorias, independientes con  $E[X_n] = \mu_n < \infty$  y  $\text{Var}[X_n] = \sigma_n^2 < \infty$ . Definimos  $s_n^2 := \text{Var}[S_n] = \sum_{j=1}^n \sigma_j^2$ . Entonces

1.  $\frac{1}{s_n} \sum_{j=1}^n (X_j - \mu_j) \xrightarrow{d} Z \sim N(0, 1)$ ,
2.  $\max_{1 \leq j \leq n} \frac{\sigma_j^2}{s_n^2} \xrightarrow[n \rightarrow \infty]{} 0$

es equivalente a

$$L_n(\varepsilon) = \frac{1}{s_n^2} \sum_{j=1}^n \int_{|x - \mu_j| > \varepsilon s_n} (x - \mu_j)^2 dF_j(x) \xrightarrow[n \rightarrow \infty]{} 0.$$