
AMPLIACIÓN DE LA TEORÍA DE LA PROBABILIDAD

Basado en las clases y apuntes de Antonio Jesús Barrera García



Autor:
Jorge Rodríguez Domínguez

Índice general

1. Función de distribución	1
1.1. Propiedades	1
1.2. Convolución de funciones de distribución	5
1.3. Convergencia en distribución	6
2. Función característica	11
2.1. Función característica	11
2.2. Función generatriz de momentos y Función generatriz de cumulantes	17
3. Convergencia	21

Capítulo 1

Función de distribución

1.1. Propiedades

Definición 1.1. Sea X una variable aleatoria en (Ω, \mathcal{A}, P) , P_X medida de probabilidad inducida por X en $(\mathbb{R}, \mathcal{B})$. La función de distribución asociada a X es $F : \mathbb{R} \longrightarrow [0, 1]$ dada por

$$F(a) = P_X((-\infty, a]) \equiv P(X \leq a)$$

Las propiedades de F son

1. F es monótona no decreciente.
2. $\lim_{x \rightarrow -\infty} F(x) = 0$ y $\lim_{x \rightarrow \infty} F(x) = 1$.
3. F es continua por la derecha, es decir, $\lim_{h \rightarrow 0^+} F(x+h) = F(x)$ para todo $x \in \mathbb{R}$.
4. Existe el límite por la izquierda, es decir, $\lim_{h \rightarrow 0^-} F(x+h) = F(x^-) = F(x) - P_X(\{x\})$ para todo $x \in \mathbb{R}$.

Teorema 1.2 (de correspondencia). Si $F : \mathbb{R} \longrightarrow [0, 1]$ es una función

- Monótona no decreciente.
- $F(-\infty) = 0$ y $F(\infty) = 1$.
- Continua por la derecha

Entonces existe (y es única) una medida de probabilidad P_F que $(\mathbb{R}, \mathcal{B})$ tal que F es su función de distribución.

Definición 1.3. Sea F una función de distribución. Definimos

- El conjunto de continuidad de F como

$$C(F) = \{x \in \mathbb{R} : F(x) = F(x^-)\}$$

- El conjunto de discontinuidad de F como

$$D(F) = \{x \in \mathbb{R} : F(x) - F(x^-) > 0\}$$

Observación 1.4. Es fácil ver que $D(F) = \overline{C(F)}$.

Proposición 1.5. $D(F)$ es a lo sumo numerable.

Demostración. Definimos la sucesión de conjuntos

$$D_n(F) = \left\{ x \in \mathbb{R} : F(x) - F(x^-) \geq \frac{1}{n} \right\}$$

Es claro que $\{D_n\}$ es una sucesión creciente. Veamos que $\#D_n(F)$ es finito. Por el teorema de correspondencia, existe una única P_F medida de probabilidad asociada a F , es decir, $P_F(\{x\}) = F(x) - F(x^-)$ para todo $x \in \mathbb{R}$. Podemos usar que P_F para "medir" $D_n(F)$ de la siguiente manera:

$$P_F(D_n(F)) = \sum_{x \in D_n(F)} P_F(\{x\}) \geq \sum_{x \in D_n(F)} \frac{1}{n} = \frac{1}{n} \#D_n(F)$$

de donde deducimos que $\#D_n(F) \leq n$. Como $\{D_n\}$ es una sucesión creciente, entonces

$$D(F) = \lim_{n \rightarrow \infty} D_n(F) = \bigcup_{n=1}^{\infty} D_n(F)$$

lo que demuestra que $D(F)$ es a lo sumo numerable. □

Corolario 1.6. $C(F)$ es denso en \mathbb{R} .

Demostración. Como $D(F) = \overline{C(F)}$ y $D(F)$ es a lo sumo numerable, tenemos que si $x \in \mathbb{R}$, o bien $x \in C(F)$, o bien $x \in D(F)$, por lo que cualquier bola $B(x, \varepsilon)$ contiene puntos de $C(F)$. □

Proposición 1.7. Sean F y G funciones de distribución tales que $F(x) = G(x)$ para todo $x \in E \subset \mathbb{R}$ con E denso en \mathbb{R} . Entonces $F(x) = G(x)$ para todo $x \in \mathbb{R}$.

Demostración. Sea $x \in \mathbb{R}$. Como E es denso en \mathbb{R} , existe una sucesión $\{x_n\} \subset E$ tal que $x_n \rightarrow x$ de forma decreciente ($x_n \downarrow x$) cuando $n \rightarrow \infty$. Entonces $F(x_n) = G(x_n)$ para todo $x_n \in E$ (por hipótesis). Como F y G son funciones de distribución, tenemos que

$$\begin{aligned} \lim_{n \rightarrow \infty} F(x_n) &= F(x) \\ \lim_{n \rightarrow \infty} G(x_n) &= G(x) \end{aligned}$$

Por la unicidad del límite, $F(x) = G(x)$. □

Definición 1.8. La función de masa de probabilidad es $p : \mathbb{R} \rightarrow [0, 1]$ dada por

$$p(x) = P_F(\{x\}).$$

Definición 1.9. Sea X una variable aleatoria con función de distribución F y función de masa p . Diremos que

- X es una variable aleatoria discreta cuando

$$\sum_{x \in D(F)} p(x) = 1$$

- X es una variable aleatoria continua cuando $p(x) = 0$ para todo $x \in \mathbb{R}$.
- X es una variable aleatoria singular si existe $B \in \mathcal{B}$ tal que $m(B) = 0$ (medida de Lebesgue) y $P_X(B) = 1$.
- X es una variable aleatoria absolutamente continua si para cualquier $B \in \mathcal{B}$ con $m(B) = 0$ se tiene que $P_X(B) = 0$.

Teorema 1.10 (Radon-Nikodyn). *Sea F función de distribución. Entonces F es absolutamente continua si y solo si existe una función medible f no negativa y finita tal que para cualquier $a < b$, $a, b \in \mathbb{R}$ se tiene que*

$$F(b) - F(a) = \int_a^b f(x) dx.$$

Teorema 1.11 (Primera descomposición). *Toda función de distribución F se puede descomponer de la forma*

$$F = \alpha F_d + (1 - \alpha) F_c,$$

donde $0 \leq \alpha \leq 1$, F_d es la función de distribución de una variable aleatoria discreta y F_c es la función de distribución de una variable aleatoria continua.

Demostración. Sea $D(F)$ el conjunto de discontinuidad de F . Definimos $\alpha = \sum_{x \in D(F)} p(x)$, donde p es la función de masa.

- Si $\alpha = 0$, entonces $F = F_c$ y es continua.
- Si $\alpha = 1$, entonces $F = F_d$ y es discreta.
- Si $0 < \alpha < 1$, definimos

$$F_d(x) = \frac{1}{\alpha} \sum_{D(F) \ni y \leq x} p(y)$$

$$F_c(x) = \frac{1}{1 - \alpha} (F(x) - \alpha F_d(x))$$

Por definición, F_d es discreta. Veamos que F_c es continua, para ello hay que ver que $F_c(x) - F_c(x^-) = 0$ para todo $x \in \mathbb{R}$. Sea $x \in \mathbb{R}$, entonces

$$\begin{aligned} F_c(x) - F_c(x^-) &= \frac{1}{1 - \alpha} (F(x) - \alpha F_d(x) - F(x^-) + \alpha F_d(x^-)) \\ &= \frac{1}{1 - \alpha} (F(x) - F(x^-) - \alpha (F_d(x) - F_d(x^-))) \\ &= \frac{1}{1 - \alpha} \left(p(x) - \alpha \frac{1}{\alpha} p(x) \right) = 0 \end{aligned}$$

□

Lema 1.12. *Sea F una función de distribución. Entonces*

- a) *Existe F' en casi todo punto, es no negativa y finita.*
- b) *$\int_a^b F'(x) dx \leq F(b) - F(a)$ para todo $a < b$, $a, b \in \mathbb{R}$.*
- c) *Siendo $F_{ac} = \int_{-\infty}^x F'(t) dt$ y $F_s(x) = F(x) - F_{ac}(x)$, entonces $F'_{ac}(x) = F'(x)$ en casi todo punto y $F'_s(x) = 0$.*

Teorema 1.13 (Segunda descomposición). *Toda función de distribución F se puede descomponer de la forma*

$$F = \beta F_{ac} + (1 - \beta) F_s,$$

donde $0 \leq \beta \leq 1$, F_{ac} es la función de distribución de una variable aleatoria absolutamente continua y F_s es la función de distribución de una variable aleatoria singular.

Demostración. Sea $f \equiv F'$ donde exista. Definimos $\beta = \int_{-\infty}^{\infty} f(x) dx$.

- Si $\beta = 1$, entonces $F = F_{ac}$ y es absolutamente continua.
- Si $\beta = 0$, entonces $F = F_s$ y es singular.
- Si $0 < \beta < 1$, definimos

$$F_{ac}(x) = \frac{1}{\beta} \int_{-\infty}^x f(t) dt$$

$$F_s(x) = \frac{1}{1-\beta} (F(x) - \beta F_{ac}(x))$$

Por definición, F_{ac} es absolutamente continua. Veamos que F_s es singular, para ello hemos de probar que $F'_s = 0$.

$$F'_s(x) = \frac{1}{1-\beta} \left(f(x) - \beta \frac{1}{\beta} f(x) \right) = 0$$

□

Observación 1.14. Aplicando la primera descomposición a F_s , tenemos que

$$\begin{aligned} F &= \beta F_{ac} + (1-\beta)[\alpha F_d + (1-\alpha)F_{cs}] \\ &= \beta F_{ac} + (1-\beta)\alpha F_d + (1-\beta)(1-\alpha)F_{cs} \\ &= \beta F_{ac} + \gamma F_d + (1-\beta-\gamma)F_{cs} \end{aligned}$$

siendo $\gamma = (1-\beta)\alpha$ y $\beta + \gamma \leq 1$.

Recordemos ahora el concepto de esperanza matemática.

Definición 1.15. Sea X una variable aleatoria en (Ω, \mathcal{A}, P) . Definimos la esperanza de X como $E(X) = \int_{\Omega} X dP$.

Usando el siguiente Teorema de Teoría de la Medida e Integración

Teorema 1.16. Sean (X, \mathcal{M}, μ) e (Y, \mathcal{N}, ν) dos espacios de medida y sea $T : X \rightarrow Y$ una aplicación $(\mathcal{M}, \mathcal{N})$ -medible que conserva las medidas. Si $g : Y \rightarrow [0, +\infty]$ es medible entonces

$$\int_Y g d\nu = \int_X g \circ T d\mu.$$

es fácil ver que

- Si F es la función de distribución de una variable aleatoria absolutamente continua, entonces

$$E(X) = \int_{\mathbb{R}} x \cdot f(x) dx.$$

- Si F es la función de distribución de una variable aleatoria discreta, entonces

$$E(X) = \sum_{x \in D(F)} x \cdot p(x).$$

1.2. Convolución de funciones de distribución

Definición 1.17. Sean F y G funciones de distribución. Definimos la convolución de F y G como la función

$$(F * G)(z) = \int_{\mathbb{R}} F(z - y) dG(y), \quad z \in \mathbb{R}.$$

Proposición 1.18. $F * G$ es una función de distribución.

Demostración. 1. $F * G$ es monótona no decreciente. Sean $a < b$, $a, b \in \mathbb{R}$, entonces

$$(F * G)(a) = \int_{\mathbb{R}} F(a - y) dG(y) \leq \int_{\mathbb{R}} F(b - y) dG(y) = (F * G)(b),$$

donde usamos que F es función de distribución.

2. $\lim_{x \rightarrow -\infty} (F * G)(x) = 0$ y $\lim_{x \rightarrow \infty} (F * G)(x) = 1$.

$$\begin{aligned} \lim_{x \rightarrow -\infty} (F * G)(x) &= \lim_{x \rightarrow -\infty} \int_{\mathbb{R}} F(x - y) dG(y) = \int_{\mathbb{R}} \lim_{x \rightarrow -\infty} F(x - y) dG(y) = \int_{\mathbb{R}} 0 dG(y) = 0 \\ \lim_{x \rightarrow \infty} (F * G)(x) &= \lim_{x \rightarrow \infty} \int_{\mathbb{R}} F(x - y) dG(y) = \int_{\mathbb{R}} \lim_{x \rightarrow \infty} F(x - y) dG(y) = \int_{\mathbb{R}} 1 dG(y) = 1 \end{aligned}$$

donde usamos que F y G son funciones de distribución.

3. $F * G$ es continua por la derecha, es decir, $\lim_{h \rightarrow 0^+} (F * G)(x + h) = (F * G)(x)$ para todo $x \in \mathbb{R}$.

$$\begin{aligned} \lim_{h \rightarrow 0^+} (F * G)(x + h) &= \lim_{h \rightarrow 0^+} \int_{\mathbb{R}} F(x + h - y) dG(y) \\ &= \int_{\mathbb{R}} \lim_{h \rightarrow 0^+} F(x + h - y) dG(y) \\ &= \int_{\mathbb{R}} F(x - y) dG(y) = (F * G)(x) \end{aligned}$$

donde usamos el Teorema de la Convergencia Dominada y que F es función de distribución.

4. Existe el límite por la izquierda, es decir, $\lim_{h \rightarrow 0^-} (F * G)(x + h) = (F * G)(x^-)$ para todo $x \in \mathbb{R}$.

$$\begin{aligned} \lim_{h \rightarrow 0^-} (F * G)(x + h) &= \lim_{h \rightarrow 0^-} \int_{\mathbb{R}} F(x + h - y) dG(y) \\ &= \int_{\mathbb{R}} \lim_{h \rightarrow 0^-} F(x + h - y) dG(y) \\ &= \int_{\mathbb{R}} F(x^- - y) dG(y) = (F * G)(x^-) \end{aligned}$$

donde usamos el Teorema de la Convergencia Dominada y que F es función de distribución. □

Teorema 1.19. Sean X e Y variables aleatorias independientes con funciones de distribución F_X y F_Y respectivamente. Entonces $F_X * F_Y$ es la función de distribución de $X + Y$.

Demostración. Definimos la variable aleatoria $Z = X + Y$. Si llamamos $F_{(X,Y)}$ a la función de distribución conjunta del par (X, Y) , entonces la función de distribución de Z es

$$\begin{aligned} F_Z(z) &= P(Z \leq z) = P(X + Y \leq z) = \int_{\{(x,y) \in \mathbb{R}^2 : x+y \leq z\}} dF_{(X,Y)}(x, y) \\ &= \int_{-\infty}^{\infty} \int_{-\infty}^{z-y} dF_X(x) dF_Y(y) = \int_{\mathbb{R}} F_X(z - y) dF_Y(y) = (F_X * F_Y)(z) \end{aligned}$$

□

Teorema 1.20. Si F es una función de distribución absolutamente continua con densidad f , entonces $F * G$ es una función de distribución absolutamente continua con densidad

$$(f * G)(s) = \int_{-\infty}^{\infty} f(s - y) dG(y).$$

Demostración.

$$\begin{aligned} (F * G)(z) &= \int_{-\infty}^{\infty} \int_{-\infty}^{z-y} f(s) ds dG(y) = \int_{-\infty}^{\infty} \int_{-\infty}^z f(s - y) ds dG(y) \\ &= \int_{-\infty}^z \int_{-\infty}^{\infty} f(s - y) dG(y) ds \end{aligned}$$

□

Teorema 1.21. Si F y G son funciones de distribución absolutamente continuas con densidades f y g respectivamente, entonces $F * G$ es una función de distribución absolutamente continua con densidad $f * g$.

Demostración.

$$\begin{aligned} (F * G)(z) &= \int_{-\infty}^{\infty} \int_{-\infty}^{z-y} f(s) ds dG(y) = \int_{-\infty}^{\infty} \int_{-\infty}^z f(s - y) ds dG(y) \\ &= \int_{-\infty}^z \int_{-\infty}^{\infty} f(s - y) dG(y) ds = \int_{-\infty}^z \int_{-\infty}^{\infty} f(s - y)g(y) dy ds \end{aligned}$$

□

1.3. Convergencia en distribución

Para cada $n \in \mathbb{N}$, tenemos una variable aleatoria X_n en $(\Omega, \mathcal{A}_n, P_n)$. De esta forma $\{X_n\}$ tiene una sucesión asociada $\{F_n\}$ de funciones de distribución.

Definición 1.22. Sea F y F_n , $n \in \mathbb{N}$, funciones de distribución. Decimos que la sucesión $\{F_n\}$ converge a F débilmente (o en distribución), y se denota como $F_n \xrightarrow{d} F$, cuando

$$\lim_{n \rightarrow \infty} F_n(x) = F(x)$$

para todo $x \in C(F)$.

Teorema 1.23. El límite débil es único.

Demostración. Sea $\{F_n\}$ una sucesión de funciones de distribución tal que $F_n \xrightarrow{d} F$ y $F_n \xrightarrow{d} G$, con F y G funciones de distribución. Entonces

$$\begin{aligned} \lim_{n \rightarrow \infty} F_n(x) &= F(x) \quad \forall x \in C(F) \\ \lim_{n \rightarrow \infty} F_n(x) &= G(x) \quad \forall x \in C(G) \end{aligned}$$

De aquí

$$F(x) = G(x) \quad \forall x \in C(F) \cap C(G)$$

Como $C(F)$ y $C(G)$ son densos en \mathbb{R} , entonces $C(F) \cap C(G)$ es denso en \mathbb{R} y por tanto, $F \equiv G$ para todo $x \in \mathbb{R}$. □

Definición 1.24. La sucesión de variables aleatorias $\{X_n\}$ converge en distribución a otra variable aleatoria X cuando $F_n \xrightarrow{d} F$, siendo F_n y F las funciones de distribución asociadas a X_n y X respectivamente.

Definición 1.25. Sean P y P_n , $n \in \mathbb{N}$, medidas de probabilidad en $(\mathbb{R}, \mathcal{B})$. Decimos que la sucesión de medidas $\{P_n\}$ converge débilmente a P cuando

$$\lim_{n \rightarrow \infty} P_n((a, b]) = P((a, b])$$

para todo $a < b$ con $P(a) = P(b) = 0$.

Lema 1.26. $F_n \xrightarrow{d} F$ si y solo si para todo $x \in \mathbb{R}$ se tiene que

$$\limsup_{n \rightarrow \infty} F_n(x) \leq F(x) \quad y \quad \liminf_{n \rightarrow \infty} F_n(x^-) \geq F(x).$$

Demostración. $\boxed{\Leftarrow}$ Tenemos que para todo $x \in \mathbb{R}$

$$F(x^-) \leq \liminf_{n \rightarrow \infty} F_n(x) \leq \limsup_{n \rightarrow \infty} F_n(x) \leq F(x).$$

Si $x \in C(F)$, entonces $F(x) = F(x^-)$, y en consecuencia

$$\liminf_{n \rightarrow \infty} F_n(x) = \limsup_{n \rightarrow \infty} F_n(x) = F(x),$$

es decir, $F_n \xrightarrow{d} F$.

$\boxed{\Rightarrow}$ Sea $x \in \mathbb{R}$ e $y \in C(F)$, $y > x$. Entonces

$$F_n(x) \leq F(y) \implies \limsup_{n \rightarrow \infty} F_n(x) \leq \limsup_{n \rightarrow \infty} F_n(y) = \lim_{n \rightarrow \infty} F_n(y) = F(y).$$

Como $C(F)$ es denso en \mathbb{R} , podemos tomar una sucesión de puntos de $C(F)$ que tienda a x (en nuestro caso, de manera decreciente), y así

$$\limsup_{n \rightarrow \infty} F_n(x) \leq \lim_{y \downarrow x} F(y) = F(x),$$

donde la última igualdad es cierta por ser F función de distribución. Usando un argumento análogo, sea $z < x$, $z \in C(F)$, entonces

$$\liminf_{n \rightarrow \infty} F_n(x) \geq \liminf_{n \rightarrow \infty} F_n(z) = F(z).$$

Al igual que antes, podemos tomar una sucesión de puntos de $C(F)$ que tienda a x (en nuestro caso, de manera creciente), y así

$$\liminf_{n \rightarrow \infty} F_n(x) \geq \lim_{z \uparrow x} F(z) = F(x^-).$$

□

Teorema 1.27 (Helly-Bray). Sean F_n , F funciones de distribución ($n > 0$). Entonces $F_n \xrightarrow{d} F$ si y solo si para toda función g real, continua y acotada se tiene que

$$\lim_{n \rightarrow \infty} \int_{\mathbb{R}} g(x) dF_n(x) = \int_{\mathbb{R}} g(x) dF(x).$$

Definición 1.28. Una función F se dice función de distribución impropia si verifica:

- (i) Es monótona no decreciente.

(ii) Es continua por la derecha.

(iii) Para cada $x \in \mathbb{R}$ existe

$$\lim_{h \rightarrow 0^-} F(x+h) = F(x^-).$$

(iv)

$$\lim_{x \rightarrow \infty} F(x) > 0 \quad \text{ò} \quad \lim_{x \rightarrow \infty} F(x) < 1.$$

Definición 1.29. Sea $\{F_n\}$ sucesión de funciones de distribución y F función de distribución (propia o impropia). Decimos que $\{F_n\}$ converge de forma vaga a F si

$$\lim_{n \rightarrow \infty} F_n(x) = F(x)$$

para todo $x \in C(F)$. Se denota como $F_n \xrightarrow{v} F$.

Observación 1.30. Es claro que $F_n \xrightarrow{d} F \implies F_n \xrightarrow{v} F$.

Teorema 1.31. Supongamos que $F_n \xrightarrow{v} F$, siendo F una función de distribución impropia. Sea g una función real y continua en $[a, b]$, siendo $a < b$ y $a, b \in C(F)$. Entonces

$$\lim_{n \rightarrow \infty} \int_a^b g(x) dF_n(x) = \int_a^b g(x) dF(x)$$

Teorema 1.32. Supongamos que $F_n \xrightarrow{v} F$, siendo F una función de distribución impropia. Sea g una función real y continua en \mathbb{R} y tal que $g(+\infty) = g(-\infty) = 0$. Entonces

$$\lim_{n \rightarrow \infty} \int_{\mathbb{R}} g(x) dF_n(x) = \int_{\mathbb{R}} g(x) dF(x)$$

Lema 1.33. $\{F_n\}$ converge vagamente si y solo si converge puntualmente en algún conjunto denso $D \subset \mathbb{R}$.

Demostración. $\boxed{\implies}$ Es directo, pues basta tomar $D = C(F)$.

$\boxed{\impliedby}$ Sea $r \in D$, definimos

$$F_D(r) = \lim_{n \rightarrow \infty} F_n(r).$$

Sabemos que $0 \leq F_D(r) \leq 1$ para cada $r \in D$. Si $s \in D$ es tal que $r < s$, entonces

$$F_D(r) = \lim_{n \rightarrow \infty} F_n(r) \leq \lim_{n \rightarrow \infty} F_n(s) = F_D(s),$$

pues F_n es función de distribución, lo que nos dice que F_D es monótona no decreciente. Ahora, sea $x \in \mathbb{R}$, definimos

$$F(x) = \lim_{r \downarrow x, r \in D} F_D(r) = \inf \Pi_x,$$

donde

$$\Pi_x = \{F_D(r) : r > x, r \in D\}.$$

Es claro que $0 \leq F(x) \leq 1$ para cada $x \in \mathbb{R}$. Veamos que F es continua por la derecha, para ello hemos de probar que $F(x) = F(x^+)$ para cada $x \in \mathbb{R}$. Sean $x, y \in \mathbb{R}$, $r \in D$ tales que $x < y < r$, entonces

$$F(y) = \inf \Pi_y \leq F_D(r),$$

pues $F_D(r) \in \Pi_y$. Entonces

$$F(x^+) = \lim_{y \downarrow x} F(y) \leq F_D(r).$$

Además $F(x^+) \leq \inf \Pi_x = F(x)$ (pues $x^+ > x$) y como F es monótona no decreciente, tenemos que $F(x) \leq F(x^+)$, por tanto, $F(x) = F(x^+)$.

Con todo esto, hemos probado que F es función de distribución impropia. Veamos que $F_n \xrightarrow{v} F$ en $C(F)$. Sean $x \in C(F)$, $r', s \in D$ tales que $r' < x < s$, entonces

$$\begin{aligned} \inf \Pi_r = F(r) &\leq F_D(r) \leq \lim_{n \rightarrow \infty} F_n(r) = \lim_{n \rightarrow \infty} \inf F_n(r) \leq \lim_{n \rightarrow \infty} \inf F_n(x) \\ &\leq \limsup_{n \rightarrow \infty} F_n(s) = F_D(s) \leq F(s) = \inf \Pi_s. \end{aligned}$$

Tomando $r < r'$, $r \in D$, tenemos que

$$\inf \Pi_r = F(r) \leq F_D(r').$$

Si tomamos límite $r \uparrow x$, $s \downarrow x$, tenemos que

$$F(x) \leq \liminf_{n \rightarrow \infty} F_n(x) \leq \limsup_{n \rightarrow \infty} F_n(x) \leq F(x),$$

de donde concluimos que

$$\lim_{n \rightarrow \infty} F_n(x) = F(x)$$

para cada $x \in C(F)$, es decir, $F_n \xrightarrow{v} F$. □

Teorema 1.34 (Principio de selección de Helly). *Dada $\{F_n\}$, $n \in \mathbb{N}$, sucesión de funciones de distribución, existe alguna subsucesión que converge vagamente.*

Definición 1.35. Sea \mathcal{H} familia de funciones de distribución. Diremos que \mathcal{H} es ajustada si para cada $\varepsilon > 0$, existe $a > 0$ tal que

$$P_F((-a, a]) > 1 - \varepsilon,$$

para cada $F \in \mathcal{H}$.

Definición 1.36. Sea \mathcal{H} una familia de funciones de distribución. Diremos que \mathcal{H} es relativamente compacta (respecto de la convergencia debil) si cada sucesión $\{F_n\}$, $F_n \in \mathcal{H}$, tiene un subsucesión convergente (de forma debil, a un límite no esté necesariamente en \mathcal{H}).

Teorema 1.37 (Prokhorov). *Sea \mathcal{H} una familia de funciones de distribución. \mathcal{H} es relativamente compacta si y solo si es ajustada.*

Capítulo 2

Función característica

2.1. Función característica

Definición 2.1. Sea X una variable aleatoria en (Ω, \mathcal{A}, P) . La función característica asociada a X es $\varphi_X : \mathbb{R} \rightarrow \mathbb{C}$ dada por

$$\varphi_X(t) = E[e^{itX}] = \int_{\mathbb{R}} e^{itx} dF(x).$$

Si $Y : \Omega \rightarrow \mathbb{R}^d$, $d \geq 1$, es un vector de variables aleatorias, entonces $\varphi_Y : \mathbb{R}^d \rightarrow \mathbb{C}$ viene dada por

$$\varphi_Y(t) = \int_{\mathbb{R}^d} e^{i\langle t, x \rangle} dF(x),$$

siendo $\langle \cdot, \cdot \rangle$ un producto escalar en \mathbb{R}^d .

Observación 2.2. Como $e^{itx} = \cos(tx) + i \sin(tx)$, entonces

$$\varphi_X(t) = \int_{\mathbb{R}} \cos(tx) dF(x) + i \int_{\mathbb{R}} \sin(tx) dF(x).$$

Algunas propiedades de la función característica son

1. $\varphi(0) = 1$.
2. $|\varphi(t)| \leq 1$ para todo $t \in \mathbb{R}$.

Demostración.

$$|\varphi(t)| = |E[e^{itX}]| \leq E[|e^{itX}|] = 1.$$

□

3. $\varphi(-t) = \overline{\varphi(t)}$ para todo $t \in \mathbb{R}$.

Demostración.

$$\begin{aligned} \varphi(-t) &= E[e^{-itX}] = E[\cos(-tx) + i \sin(-tx)] = E[\cos(tx) - i \sin(tx)] \\ &= \overline{E[\cos(tx)] + i E[\sin(tx)]} = \overline{E[\cos(tx) + i \sin(tx)]} = \overline{\varphi(t)}. \end{aligned}$$

□

4. φ es una función definida positiva, es decir, para cada $n \in \mathbb{N}$ y para cada $z \in \mathbb{C}^n$, $z = (z_1, \dots, z_n)$ se tiene que

$$\sum_{k,j=1}^n z_k \varphi(t_j - t_k) \overline{z_j} \geq 0.$$

Demostración.

$$\begin{aligned} \sum_{k,j=1}^n z_k \varphi(t_j - t_k) \overline{z_j} &= \sum_{k,j=1}^n z_k E \left[e^{i(t_j - t_k)X} \right] \overline{z_j} = \sum_{k,j=1}^n z_k E \left[e^{it_j X} e^{-it_k X} \right] \overline{z_j} \\ &= E \left[\sum_{k,j=1}^n z_k e^{it_j X} e^{-it_k X} \overline{z_j} \right] = E \left[\sum_{k=1}^n z_k e^{-it_k X} \left(\sum_{j=1}^n \overline{z_j} e^{it_j X} \right) \right] \\ &= E \left[\sum_{k=1}^n z_k e^{-it_k X} \overline{\left(\sum_{j=1}^n z_j e^{-it_j X} \right)} \right] = E \left[\left| \sum_{k=1}^n z_k e^{-it_k X} \right|^2 \right] \geq 0. \end{aligned}$$

□

Teorema 2.3. φ es uniformemente continua.

Demostración. Sean $t, h \in \mathbb{R}$, entonces

$$\begin{aligned} |\varphi(t+h) - \varphi(t)| &= \left| E \left[e^{i(t+h)X} \right] - E \left[e^{itX} \right] \right| = \left| E \left[e^{i(t+h)X} - e^{itX} \right] \right| \\ &= \left| E \left[e^{itX} (e^{ihX} - 1) \right] \right| \leq E \left[|e^{itX} (e^{ihX} - 1)| \right] \\ &= E \left[|e^{itX}| |e^{ihX} - 1| \right] = E \left[|e^{ihX} - 1| \right] \end{aligned}$$

Como

- $|e^{ihX} - 1| \leq |e^{ihX}| + 1 = 2.$
- $|e^{ihX} - 1| \xrightarrow{h \rightarrow 0} 0.$

Por el Teorema de la Convergencia Dominada, $E[e^{ihX} - 1] \xrightarrow{h \rightarrow 0} 0$, de donde, $|\varphi(t+h) - \varphi(t)| \xrightarrow{h \rightarrow 0} 0$ para cada $t \in \mathbb{R}$, lo que nos dice que φ es uniformemente continua. □

Teorema 2.4 (de inversión). Sea X una variable aleatoria en (Ω, \mathcal{A}, P) con función de distribución F y función característica φ . Dados $a, b \in \mathbb{R}$, $a < b$, se tiene que

$$\frac{F(b) + F(b^-)}{2} - \frac{F(a) + F(a^-)}{2} = \lim_{T \rightarrow \infty} \int_{-T}^T \frac{e^{-itb} - e^{-ita}}{-it} \varphi(t) dt.$$

Demostración. Observamos que

$$\left| \frac{e^{-itb} - e^{-ita}}{-it} \right| = \left| \int_a^b e^{-itx} dx \right| \leq \int_a^b |e^{-itx}| = b - a < \infty.$$

Usando el Teorema de Fubini

$$\begin{aligned} \frac{1}{2\pi} \int_{-T}^T \frac{e^{-itb} - e^{-ita}}{-it} \varphi(t) dt &= \frac{1}{2\pi} \int_{-T}^T \frac{e^{-itb} - e^{-ita}}{-it} \left(\int_{-\infty}^{\infty} e^{itx} dF(x) \right) dt \\ &= \frac{1}{\pi} \int_{-\infty}^{\infty} \int_{-T}^T \frac{e^{-it(x-a)} - e^{-it(x-b)}}{2it} dt dF(x). \end{aligned}$$

Llamemos

$$I(t) := \int_{-T}^T \frac{e^{-it(x-a)} - e^{-it(x-b)}}{2it} dt,$$

así

$$\begin{aligned} I(T) &= \int_{-T}^T \frac{\cos(t(x-a)) + i \operatorname{sen}(t(x-a)) - \cos(t(x-b)) - i \operatorname{sen}(t(x-b))}{2it} dt \\ &= \int_0^T \frac{i2 \operatorname{sen}(t(x-a)) - i2 \operatorname{sen}(t(x-b))}{2it} dt = \int_0^T \left(\frac{\operatorname{sen}(t(x-a))}{t} - \frac{\operatorname{sen}(t(x-b))}{t} \right) dt. \end{aligned}$$

Definimos ahora la función

$$H(y) = \int_0^y \frac{\operatorname{sen}(t)}{t} dt,$$

que sabemos que verifica que $H(-y) = H(y)$ y $\lim_{y \rightarrow \infty} H(y) = \pi/2$. Consideremos ahora el cambio de variables $u = t(x-a)$, de esta forma

$$\int_0^T \frac{\operatorname{sen}(t(x-a))}{t} dt = \int_0^{T(x-a)} \frac{\operatorname{sen}(u)}{u} du = H(T(x-a)) \xrightarrow{T \rightarrow \infty} \begin{cases} -\pi/2 & x < a \\ 0 & x = a \\ \pi/2 & x > a \end{cases}.$$

Actuando de igual forma para el cambio $u = t(x-b)$, llegamos a que

$$\lim_{T \rightarrow \infty} \int_0^T \left(\frac{\operatorname{sen}(t(x-a))}{t} - \frac{\operatorname{sen}(t(x-b))}{t} \right) dt = \begin{cases} 0 & x < a \\ \pi/2 & x = a \\ \pi & a < x < b \\ \pi/2 & x = b \\ 0 & x > b \end{cases}.$$

Entonces

$$\begin{aligned} \lim_{T \rightarrow \infty} \frac{1}{2\pi} \int_{-T}^T \frac{e^{-itb} - e^{-ita}}{-it} \varphi(b) dt &= \lim_{T \rightarrow \infty} \frac{1}{\pi} \int_{-\infty}^{\infty} I(t) dF(x) = \int_{-\infty}^{\infty} \lim_{T \rightarrow \infty} \frac{1}{\pi} I(t) dF(x) \\ &= \frac{1}{\pi} \left(\frac{\pi}{2} P(X=a) + \pi P(a < X < b) + \frac{\pi}{2} P(X=b) \right) \\ &= \frac{1}{\pi} \left(\frac{\pi}{2} (F(a) - F(a^-)) + \pi (F(b^-) - F(a)) + \frac{\pi}{2} (F(b) - F(b^-)) \right) \\ &= \frac{F(b) + F(b^-)}{2} - \frac{F(a) + F(a^-)}{2}. \end{aligned}$$

□

Corolario 2.5. Sea X una variable aleatoria en (Ω, \mathcal{A}, P) con función de distribución F y función característica φ . Dados $a, b \in C(F)$, $a < b$, se tiene que

$$F(b) - F(a) = \lim_{T \rightarrow \infty} \int_{-T}^T \frac{e^{-itb} - e^{-ita}}{-it} \varphi(t) dt.$$

Teorema 2.6. Sean X_1 y X_2 variables aleatorias con funciones de distribución F_1 y F_2 y funciones características φ_1 y φ_2 respectivamente. Entonces $F_1 = F_2$ si y solo si $\varphi_1 = \varphi_2$.

Demostración. $\boxed{\Rightarrow}$ Supongamos que $F_1 = F_2$, entonces

$$\varphi_1(t) = E[e^{itX_1}] = \int_{\mathbb{R}} e^{itx} dF_1(x) = \int_{\mathbb{R}} e^{itx} dF_2(x) = E[e^{itX_2}] = \varphi_2(t).$$

Supongamos que $\varphi_1 = \varphi_2 \equiv \varphi$. Sean $a < b$, $a, b \in C(F_1) \cap C(F_2)$. Por el Teorema de Inversión

$$F_1(b) - F_1(a) = F_2(b) - F_2(a),$$

tomando límite $a \rightarrow \infty$, tenemos que

$$F_1(b) - 1 = F_2(b) - 1 \iff F_1(b) = F_2(b),$$

de donde deducimos que F_1 y F_2 coinciden en un denso de \mathbb{R} y por tanto, $F_1 = F_2$ en todo \mathbb{R} . \square

Teorema 2.7. *Existe $k \in (0, \infty)$ tal que para todo $a > 0$ y toda medida de probabilidad P_F (puede ser cualquier medida de probabilidad arbitraria) tal que*

$$P_F \left(\left[-\frac{1}{a}, \frac{1}{a} \right]^c \right) \leq \frac{k}{a} \int_0^a (1 - \operatorname{Re} \varphi_F(t)) dt.$$

Demostración. Nótese que

$$\operatorname{Re}(\varphi_F(t)) = \operatorname{Re} E[e^{itX}] = \operatorname{Re} E[\cos(tx) + i \sin(tx)] = E[\cos(tx)],$$

de donde

$$1 - \operatorname{Re}(\varphi_F(t)) = E[1 - \cos(tx)].$$

Así,

$$\begin{aligned} \frac{1}{a} \int_0^a (1 - \operatorname{Re}(\varphi_F(t))) dt &= \frac{1}{a} \int_0^a \int_{\mathbb{R}} (1 - \cos(tx)) dF(x) dt = \int_{\mathbb{R}} \frac{1}{a} \int_0^a (1 - \cos(tx)) dt dF(x) \\ &= \int_{\mathbb{R}} \frac{1}{a} \left(\int_0^a 1 dt - \int_0^a \cos(tx) dt \right) dF(x) = \int_{\mathbb{R}} \left(1 - \frac{\sin(ax)}{ax} \right) dF(x) \\ &\geq \int_{|ax| > 1} \left(1 - \frac{\sin(ax)}{ax} \right) dF(x) \geq \inf_{|t| > 1} \left(1 - \frac{\sin(t)}{t} \right) \cdot P_F \left(\left[-\frac{1}{a}, \frac{1}{a} \right]^c \right) \end{aligned}$$

Basta tomar

$$k = \frac{1}{\inf_{|t| > 1} \left(1 - \frac{\sin(t)}{t} \right)}$$

para obtener el resultado. \square

Corolario 2.8. *Sea $\{X_n\}$ una sucesión de variables aleatorias, con F_n , P_n y φ_n asociada a X_n . Supongamos que*

1. *Existe $\delta > 0$ tal que $\varphi_n \xrightarrow{n \rightarrow \infty} \varphi(t)$ para todo $t \in [-\delta, \delta]$.*

2. *φ es continua en 0.*

Entonces $\{X_n\}$ es ajustada, es decir, $\{F_n\}$ forma una familia ajustada.

Teorema 2.9. *Sea $\{F_n\}$ una familia ajustada de funciones de distribución. Si todas las subsucesiones convergentes tienen el mismo límite F , entonces $F_n \xrightarrow{d} F$.*

Demostración. Supongamos por reducción al absurdo que $F_n \not\xrightarrow{d} F$, entonces existe $x \in C(F)$ tal que $F_n(x) \not\rightarrow F(x)$, es decir, existe una subsucesión $\{F_{n_k}\}$ tal que $F_{n_k}(x) \rightarrow \alpha \neq F(x)$. Por hipótesis, $\{F_{n_k}\}$ es ajustada, por el Teorema de Prokhorov, existe $\{F_{n'_k}\} \subset \{F_{n_k}\}$ tal que $F_{n'_k} \rightarrow F$ (por hipótesis). Como $x \in C(F)$, entonces $F_{n'_k} \rightarrow F(x) \neq \alpha$, lo que es una contradicción. \square

Teorema 2.10 (Continuidad de Levy). Sea $\{X_n\}$ una sucesión de variables aleatorias con φ_n función característica asociada a X_n . Si existe φ función tal que

1. $\varphi_n(t) \rightarrow \varphi(t)$ para todo $t \in \mathbb{R}$.
2. φ es continua en 0.

Entonces $X_n \xrightarrow{d} X$, donde X es la variable aleatoria con función característica φ .

Demostración. Por el Corolario 2.8 tenemos que $\{X_n\}$ es una familia ajustada. Veamos que el límite de las subsucesiones de $\{F_n\}$ es único, con lo que bastaría usar el Teorema 2.9 para llegar al resultado.

Sean $\{F_{n_k}\}$ y $\{F_{n_j}\}$ subsucesiones tales que

$$F_{n_k} \xrightarrow{d} G_1, \quad F_{n_j} \xrightarrow{d} G_2.$$

Consideremos las sucesiones asociadas de funciones características

$$\varphi_{n_k}(t) \rightarrow \varphi_{G_1}(t), \quad \varphi_{n_j}(t) \rightarrow \varphi_{G_2}(t)$$

para todo $t \in \mathbb{R}$. Como $\{\varphi_{n_k}\}$ y $\{\varphi_{n_j}\}$ son subsucesiones de $\{\varphi_n\}$, entonces, por hipótesis, $\varphi_{G_1}(t) = \varphi_{G_2}(t) = \varphi(t)$ para todo $t \in \mathbb{R}$. De aquí, deducimos que

$$\int_{\mathbb{R}} e^{itx} dG_1(x) = \int_{\mathbb{R}} e^{itx} dG_2(x).$$

Como la función $t \mapsto e^{itx}$, $x \in \mathbb{R}$, es continua y acotada, entonces esta igualdad implica que $P_{G_1} = P_{G_2}$. Por el Teorema de Correspondencia, tenemos que $G_1 = G_2$. Por el Teorema 2.9 $F_n \xrightarrow{d} F$, es decir, $X_n \xrightarrow{d} X$. \square

Teorema 2.11. $\{F_n\}$ es ajustada si y solo si

$$\lim_{t \rightarrow 0} \left[\limsup_{n \rightarrow \infty} \operatorname{Re}(1 - \varphi_n(t)) \right] = 0.$$

Observación 2.12 (Teorema Central del Límite de De Moivre). Sea $\{X_n\}$ una sucesión de variables aleatorias tales que $X_n \sim \operatorname{Bi}(n, p)$. Tenemos entonces que $E[X_n] = p$ y $\operatorname{Var}[X_n] = npq$, siendo $q = 1 - p$. Si definimos las variables aleatorias

$$Z_n = \frac{X_n - np}{\sqrt{npq}},$$

tenemos que $Z_n \xrightarrow{d} Z$, siendo $Z \sim N(0, 1)$.

Demostración.

$$\begin{aligned} \varphi_{Z_n}(t) &= E[e^{itZ_n}] = E\left[e^{it \frac{X_n - np}{\sqrt{npq}}}\right] = E\left[e^{it \frac{X_n}{\sqrt{npq}}} e^{-it \frac{np}{\sqrt{npq}}}\right] = e^{-it \frac{np}{\sqrt{npq}}} E\left[e^{it \frac{X_n}{\sqrt{npq}}}\right] \\ &= e^{-it \frac{np}{\sqrt{npq}}} \varphi_{X_n}\left(\frac{t}{\sqrt{npq}}\right). \end{aligned}$$

Como $X_n \sim \operatorname{Bi}(n, p)$, entonces $\varphi_{X_n}(t) = (pe^{-it} + q)^n$. Por tanto,

$$\varphi_{Z_n}(t) = e^{-it \frac{np}{\sqrt{npq}}} \left(pe^{-i \frac{t}{\sqrt{npq}}} + q \right)^n = \left(pe^{i \frac{tq}{\sqrt{npq}}} + qe^{-i \frac{tp}{\sqrt{npq}}} \right)^n$$

Tomando límite cuando $n \rightarrow \infty$,

$$\lim_{n \rightarrow \infty} \varphi_{Z_n}(t) = \lim_{n \rightarrow \infty} \left(pe^{i \frac{tq}{\sqrt{npq}}} + qe^{-i \frac{tp}{\sqrt{npq}}} \right)^n \implies \text{Indeterminación tipo "1}^\infty\text{"}$$

Recordemos que si

$$\lim_{x \rightarrow \infty} f(x) = 1, \quad \lim_{n \rightarrow \infty} g(x) = \infty,$$

entonces,

$$\lim_{x \rightarrow \infty} f(x)^{g(x)} = e^{\lim_{x \rightarrow \infty} g(x)(f(x)-1)}.$$

Usando esto, tenemos que

$$\lim_{n \rightarrow \infty} \varphi_{Z_n}(t) = \exp \left[\lim_{n \rightarrow \infty} n \left(p e^{i \frac{tq}{\sqrt{npq}}} + q e^{-i \frac{tp}{\sqrt{npq}}} - 1 \right) \right].$$

Desarrollando la serie de Taylor de $e^{i \frac{tq}{\sqrt{npq}}}$:

$$e^{i \frac{tq}{\sqrt{npq}}} = \sum_{k=0}^{\infty} \frac{\left(i \frac{tq}{\sqrt{npq}} \right)^k}{k!} = 1 + i \frac{tq}{\sqrt{npq}} + \frac{\left(i \frac{tq}{\sqrt{npq}} \right)^2}{2!} + o\left(\frac{t^2}{npq} \right),$$

de donde,

$$\begin{aligned} & p e^{i \frac{tq}{\sqrt{npq}}} + q e^{-i \frac{tp}{\sqrt{npq}}} - 1 \\ &= p \left[1 + i \frac{tq}{\sqrt{npq}} + \frac{\left(i \frac{tq}{\sqrt{npq}} \right)^2}{2!} \right] + q \left[1 - i \frac{tp}{\sqrt{npq}} + \frac{\left(-i \frac{tp}{\sqrt{npq}} \right)^2}{2!} \right] - 1 + o\left(\frac{t^2}{npq} \right) \\ &= p(iq)^2 \frac{t^2}{2npq} + q(ip)^2 \frac{t^2}{2npq} + o\left(\frac{t^2}{npq} \right) = -pq^2 \frac{t^2}{2npq} - qp^2 \frac{t^2}{2npq} + o\left(\frac{t^2}{npq} \right) \\ &= -\frac{t^2}{2npq} (pq^2 + qp^2) + o\left(\frac{t^2}{npq} \right) = -\frac{t^2}{2npq} pq + o\left(\frac{t^2}{npq} \right) \\ &= -\frac{t^2}{2n} + o\left(\frac{t^2}{npq} \right) = -\frac{t^2}{2n} + o\left(\frac{t^2}{n} \right). \end{aligned}$$

Finalmente,

$$\begin{aligned} \lim_{n \rightarrow \infty} \varphi_{Z_n}(t) &= \exp \left[\lim_{n \rightarrow \infty} n \left(p e^{i \frac{tq}{\sqrt{npq}}} + q e^{-i \frac{tp}{\sqrt{npq}}} - 1 \right) \right] = \exp \left[\lim_{n \rightarrow \infty} n \left(-\frac{t^2}{2n} + o\left(\frac{t^2}{n} \right) \right) \right] \\ &= e^{-t^2/2} = \varphi_Z(t), \end{aligned}$$

siendo $Z \sim N(0, 1)$. Por el Teorema de Levy, $Z_n \xrightarrow{d} Z$, $Z \sim N(0, 1)$. □

Proposición 2.13. Si $E[|X|^n] < \infty$ para cierto $n \geq 1$, entonces existen y son finitos $E[X^r]$ para cada $1 \leq r \leq n$.

Definición 2.14. El espacio L^r es el conjunto de las variables aleatorias X tales que $E[|X|^r] < \infty$, es decir,

$$L^r = \left\{ X \text{ variable aleatoria} : \int_{\mathbb{R}} |x|^r dF(x) < \infty \right\}.$$

Teorema 2.15. Sea $X \in L^n$, para cierto $n \geq 1$, con función característica φ . Entonces existen las derivadas $\varphi^{(k)}$ para $k = 1, \dots, n$, son uniformemente continuas y

$$\varphi^{(k)}(t) = i^k \int_{\mathbb{R}} x^k e^{itx} dF(x).$$

Además,

$$\varphi^{(k)}(0) = i^k E[X^k],$$

y

$$\varphi(t) = 1 + \sum_{k=1}^n \frac{(it)^k}{k!} E[X^k] + o(t^n).$$

Proposición 2.16. Sean X e Y variables aleatorias independientes con funciones características φ_X y φ_Y respectivamente. Entonces la función característica de la variable aleatoria $S = X + Y$ es $\varphi_S(t) = \varphi_X(t) \cdot \varphi_Y(t)$.

Observación 2.17. En general, si X_1, \dots, X_n son variables aleatorias independientes y $S = X_1 + \dots + X_n$, entonces

$$\varphi_S(t) = \prod_{i=1}^n \varphi_{X_i}(t).$$

Lema 2.18.

$$\left| e^{it} - \sum_{k=0}^n \frac{(iy)^k}{k!} \right| \leq \min \left\{ \frac{2|y|^n}{n!}, \frac{|y|^{n+1}}{(n+1)!} \right\}.$$

Teorema 2.19. Si φ es absolutamente integrable, entonces F es absolutamente continua y su función de densidad es

$$f(x) = \frac{1}{2\pi} \int_{\mathbb{R}} e^{itx} \varphi(t) dt.$$

Lema 2.20 (Riemann-Lebesgue). Si F es absolutamente continua entonces

$$\lim_{t \rightarrow \infty} |\varphi(t)| = 0, \quad \lim_{t \rightarrow -\infty} |\varphi(t)| = 0.$$

Lema 2.21.

$$P(X = a) = \lim_{T \rightarrow \infty} \frac{1}{2T} \int_{-T}^T e^{-ita} \varphi(t) dt.$$

2.2. Función generatriz de momentos y Función generatriz de cumulantes

Definición 2.22. Sea X una variable aleatoria con función característica φ , se define la función generatriz de cumulantes de X como $\kappa : \mathbb{R} \rightarrow \mathbb{C}$ dada por

$$\kappa(t) = \log \varphi(t).$$

Proposición 2.23. Sean X_1, \dots, X_n variables aleatorias independientes con funciones características $\varphi_1, \dots, \varphi_n$ respectivamente. Sea $S = X_1 + \dots + X_n$, entonces

$$\kappa_S(t) = \sum_{i=1}^n \kappa_{X_i}(t).$$

Teorema 2.24. Si $E[|X|^n] < \infty$ para cierto $n \geq 1$. Entonces

$$\kappa(t) = \sum_{j=0}^n \frac{(it)^j}{j!} C_j + o(t^n),$$

siendo

$$C_j = \frac{\kappa^{(j)}(0)}{i^j}.$$

C_j se conoce como el *cumulante de orden j* .

Observación 2.25. $C_1 = E[X]$ y $C_2 = \text{Var}[X]$.

Observación 2.26. Si $X \sim N(\mu, \sigma^2)$, entonces $C_1 = \mu$, $C_2 = \sigma^2$ y $C_n = 0$ para todo $n \geq 3$.

Definición 2.27. Sea X una variable aleatoria con $\sigma = \sqrt{\text{Var}[X]}$. Se definen

- Sesgo: C_3/σ^3 .
- Curtosis: C_4/σ^4 .

Definición 2.28. Sea X una variable aleatoria con función característica φ , se define la función generatriz de momentos de X como

$$\psi(t) = E[e^{tX}] = \int_{\mathbb{R}} e^{tx} dF(x),$$

siempre que exista $h > 0$ tal que ψ esté definida para todo $|t| < h$.

Observación 2.29. Si existe ψ , entonces $E[|X|^n] < \infty$ para todo $n \in \mathbb{N}$.

Definición 2.30. Sea X una variable aleatoria que toma valores en $\mathbb{Z}_+ = \{0, 1, 2, \dots\}$. La función generatriz de probabilidad de X es

$$G_X(t) = E[t^X] = \sum_{n=0}^{\infty} t^n P(X = n), \quad |t| < 1.$$

Observación 2.31.

$$G_X^{(k)}(t) = \sum_{n=k}^{\infty} n(n-1)\dots(n-k+1)t^{n-k}P(X=n)$$

$$G_X^{(k)}(0) = k!P(X=k) \implies P(X=K) = \frac{G_X^{(K)}(0)}{k!}.$$

Observación 2.32. Sea $X = Y_1 + \dots + Y_N$, siendo Y_i variables aleatorias independientes e igualmente distribuidas y N una variable aleatoria en \mathbb{Z}_+ . Entonces X sigue una distribución compuesta y su función característica es

$$\begin{aligned} \varphi_X(t) &= E[e^{itX}] = E[E[e^{itX}|N]] = \sum_{n=0}^{\infty} E[e^{itX}|N=n] P(N=n) \\ &= \sum_{n=0}^{\infty} E[e^{it \sum_{i=1}^n Y_i}|N=n] P(N=n) = \sum_{n=0}^{\infty} (\varphi_Y(t))^n P(N=n) \\ &= G_N(\varphi_Y(t)) \end{aligned}$$

Lema 2.33. Sean μ_1, \dots, μ_n medidas de probabilidad con funciones características $\varphi_1, \dots, \varphi_n$ respectivamente. Sean $\alpha_1, \dots, \alpha_n \in [0, 1]$ tales que $\sum_{i=1}^n \alpha_i = 1$. Entonces, la función característica asociada a la medida de probabilidad $\sum_{i=1}^n \alpha_i \mu_i$ es $\sum_{i=1}^n \alpha_i \varphi_i$.

Demostración.

$$\varphi(t) = \int_{\mathbb{R}} e^{itx} d(\alpha_1 \mu_1 + \dots + \alpha_n \mu_n) = \alpha_1 \int_{\mathbb{R}} e^{itx} d\mu_1 + \dots + \alpha_n \int_{\mathbb{R}} e^{itx} d\mu_n$$

□

Definición 2.34. Una función $g : \mathbb{R} \rightarrow \mathbb{C}$ es definida positiva si

$$\sum_{j=1}^n \sum_{i=1}^n g(t_j - t_i) z_j \overline{z_i} \geq 0,$$

para cualesquiera $t_1, \dots, t_n \in \mathbb{R}$ y cualesquiera $z_1, \dots, z_n \in \mathbb{C}$.

Observación 2.35. La función característica es definida positiva (se probó al inicio de este mismo capítulo).

Teorema 2.36. Si g es definida positiva y continua en 0, entonces g es uniformemente continua en \mathbb{R} .

Lema 2.37 (Herglotz). Si $\phi : \mathbb{Z} \rightarrow \mathbb{C}$ es definida positiva y $\phi(0) = 1$, entonces existe μ distribución de probabilidad en $[-\pi, \pi]$ tal que ϕ es su función característica asociada, es decir,

$$\phi(t) = \int_{-\pi}^{\pi} e^{itx} d\mu,$$

para todo $t \in \mathbb{Z}$.

Teorema 2.38 (Bochner). Sea $\varphi : \mathbb{R} \rightarrow \mathbb{C}$ verificando:

- (i) es definida positiva,
- (ii) continua en 0,
- (iii) $\varphi(0) = 1$.

Entonces, φ es función característica.

Corolario 2.39. Toda combinación lineal convexa de funciones características es función característica.

Proposición 2.40. La función φ_T dada por

$$\varphi_T(t) = \max \left\{ 1 - \frac{|t|}{T}, 0 \right\} \equiv \begin{cases} 1 - \frac{|t|}{T}, & |t| \leq T, \\ 0, & |t| > T \end{cases}, \quad T \in \mathbb{R},$$

es función característica.

Lema 2.41. Sea $\varphi : \mathbb{R} \rightarrow \mathbb{R}$ tal que $\varphi(0) = 1$, no negativa, par y φ es una poligonal convexa no creciente en \mathbb{R}^+ . Entonces φ es función característica.

Teorema 2.42 (Criterio de Pólya). Sea $\varphi : \mathbb{R} \rightarrow \mathbb{R}$ tal que:

- (i) $\varphi(0) = 1$,
- (ii) φ no negativa, par y continua.
- (iii) φ convexa y no creciente en \mathbb{R}^+ .

Entonces φ es función característica.

Capítulo 3

Convergencia

Consideremos un espacio de probabilidad (Ω, \mathcal{A}, P) , $P : \mathcal{A} \rightarrow [0, 1]$. Sean $A_1, \dots, A_n \in \mathbb{A}$ una sucesión de sucesos. Definimos el límite inferior y superior como sigue

$$\liminf_n A_n = \bigcup_{n \geq 1} \bigcap_{m \geq n} A_m \in \mathcal{A}, \quad \limsup_n A_n = \bigcap_{n \geq 1} \bigcup_{m \geq n} A_m \in \mathcal{A}.$$

Decimos que la sucesión $\{A_n\}$ converge si $\liminf_n A_n = \limsup_n A_n$. Algunos resultados que ya conocemos son los siguientes:

- Toda sucesión monótona es convergente.
- Si $\{A_n\}$ es monótona creciente, entonces $\lim_n A_n = \cup_{i \geq 1} A_i$.
- Si $\{A_n\}$ es monótona decreciente, entonces $\lim_n A_n = \cap_{i \geq 1} A_i$.

Teorema 3.1. Sea (Ω, \mathcal{A}, P) un espacio de probabilidad y consideremos $\{A_n\} \subset \mathcal{A}$ una sucesión monótona creciente. Entonces

$$P\left(\lim_n A_n\right) = \lim_n P(A_n).$$

Demostración. Como $\{A_n\}$ es creciente, entonces $\lim_n A_n = \cup_{i \geq 1} A_i$, de donde:

$$P\left(\lim_n A_n\right) = P\left(\bigcup_{i \geq 1} A_i\right).$$

Como los A_n no son disjuntos, definimos $F_n = A_n \setminus A_{n-1}$ para cada $n \geq 2$. Es claro que los F_n son disjuntos y que

$$\bigcup_{i \geq 1} A_i = A_1 \dot{\cup} F_2 \dot{\cup} \dots \dot{\cup} F_n \dot{\cup} \dots$$

De aquí,

$$\begin{aligned} P\left(\bigcup_{i \geq 1} A_i\right) &= P(A_1) + P(F_2) + \dots + P(F_n) + \dots = P(A_1) + \lim_{n \rightarrow \infty} \sum_{i=2}^n P(F_i) \\ &= P(A_1) + \lim_{n \rightarrow \infty} (P(A_n) - P(A_1)) = \lim_{n \rightarrow \infty} P(A_n). \end{aligned}$$

□

Teorema 3.2. Sea (Ω, \mathcal{A}, P) un espacio de probabilidad y consideremos $\{A_n\} \subset \mathcal{A}$ una sucesión monótona decreciente. Entonces

$$P\left(\lim_n A_n\right) = \lim_n P(A_n).$$

Demostración. Consideramos $\{A_n^c\}$, que es una sucesión monótona creciente. Por el Teorema anterior

$$P\left(\bigcup_{i \geq 1} A_i^c\right) = P\left(\lim_n A_n^c\right) = \lim_n P(A_n^c).$$

Por las leyes de De Morgan:

$$P\left(\bigcup_{i \geq 1} A_i^c\right) = P\left(\left(\bigcap_{i \geq 1} A_i\right)^c\right) = 1 - P\left(\bigcap_{i \geq 1} A_i\right)$$

Así,

$$\lim_{n \rightarrow \infty} P(A_n^c) = \lim_{n \rightarrow \infty} (1 - P(A_n)) = 1 - P\left(\bigcap_{i \geq 1} A_i\right) \implies \lim_{n \rightarrow \infty} P(A_n) = P\left(\bigcap_{i \geq 1} A_i\right)$$

□

Teorema 3.3. Sea (Ω, \mathcal{A}, P) un espacio de probabilidad y consideremos $\{A_n\} \subset \mathcal{A}$ una sucesión. Entonces

$$P\left(\limsup_n A_n\right) = \lim_n P\left(\bigcup_{m \geq n} A_m\right).$$

Demostración. Como $\limsup_n A_n = \bigcap_{n \geq 1} \bigcup_{m \geq n} A_m$, tenemos que $\{\bigcup_{m \geq n} A_m\}$ es una sucesión decreciente y

$$\bigcap_{n \geq 1} \bigcup_{m \geq n} A_m = \lim_{n \rightarrow \infty} \left(\bigcup_{m \geq n} A_m\right),$$

de donde concluimos que

$$P\left(\limsup_n A_n\right) = P\left(\bigcap_{n \geq 1} \bigcup_{m \geq n} A_m\right) = P\left(\lim_{n \rightarrow \infty} \left(\bigcup_{m \geq n} A_m\right)\right) = \lim_{n \rightarrow \infty} P\left(\bigcup_{m \geq n} A_m\right).$$

□

Teorema 3.4. Sea (Ω, \mathcal{A}, P) un espacio de probabilidad y consideremos $\{A_n\} \subset \mathcal{A}$ una sucesión. Entonces

$$P\left(\liminf_n A_n\right) = \lim_n P\left(\bigcap_{m \geq n} A_m\right).$$

Teorema 3.5. Sea (Ω, \mathcal{A}, P) un espacio de probabilidad y consideremos $\{A_n\} \subset \mathcal{A}$ una sucesión. Sea $\omega \in \Omega$, entonces $\omega \in \limsup_n A_n$ si y solo si existe una sucesión de índices $n_1 < n_2 < \dots < n_k < \dots$ tal que $\omega \in A_{n_k}$ para todo $k \in \mathbb{N}$.

Demostración. \Rightarrow Supongamos que $\omega \in \limsup A_n$, es decir,

$$\omega \in \bigcap_{n \geq 1} \bigcup_{m \geq n} A_m.$$

En particular, $\omega \in \bigcup_{m \geq 1} A_m$, es decir, existe $\xi \in \mathbb{N}$, tal que $\omega \in A_\xi$. Tomamos $n_1 = \xi$. Por inducción sobre k , suponemos que $\omega \in A_{n_i}$, $i = 1, \dots, k$. Actuando de igual forma, $\omega \in \bigcup_{m \geq n_{k+1}} A_m$, es decir, existe $\xi' \in \mathbb{N}$ tal que $\omega \in A_{\xi'}$ y tomamos $n_{k+1} = \xi'$.

\Leftarrow Por reducción al absurdo, supongamos que existe una sucesión de índices $n_1 < n_2 < \dots < n_k < \dots$ tal que $\omega \in A_{n_k}$ para todo $k \in \mathbb{N}$ y que $\omega \notin \limsup A_n$. De esto últimos, tenemos que

$$\omega \notin \bigcap_{n \geq 1} \bigcup_{m \geq n} A_m \Rightarrow \omega \in \left(\bigcap_{n \geq 1} \bigcup_{m \geq n} A_m \right)^c \Rightarrow \omega \in \bigcup_{n \geq 1} \bigcap_{m \geq n} A_m^c,$$

es decir, existe $n_0 \in \mathbb{N}$ (fijo) tal que $\omega \in A_m^c$ para todo $m \geq n_0$, es decir, $\omega \notin A_m$ para todo $m \geq n_0$, lo que nos dice que ω está en un número finito de A_n , los que es una contradicción. \square

Teorema 3.6. Sea (Ω, \mathcal{A}, P) un espacio de probabilidad y consideremos $\{A_n\} \subset \mathcal{A}$ una sucesión. Sea $\omega \in \Omega$, entonces $\omega \in \liminf_n A_n$ si y solo si existe $n_0 \in \mathbb{N}$ tal que $\omega \in A_m$ para todo $m \geq n_0$.

Teorema 3.7 (Primer Lema de Borel-Cantelli). Sea (Ω, \mathcal{A}, P) un espacio de probabilidad y consideremos $\{A_n\} \subset \mathcal{A}$ una sucesión tal que $\sum_{n \geq 1} P(A_n) < \infty$. Entonces

$$P\left(\limsup_n A_n\right) = 0.$$

Demostración.

$$\begin{aligned} P\left(\limsup_n A_n\right) &= P\left(\bigcap_{n \geq 1} \bigcup_{m \geq n} A_m\right) \stackrel{(*)}{=} P\left(\lim_{n \rightarrow \infty} \bigcup_{m \geq n} A_m\right) \\ &= \lim_{n \rightarrow \infty} P\left(\bigcup_{m \geq n} A_m\right) \leq \lim_{n \rightarrow \infty} \sum_{m \geq n} P(A_n) = 0. \end{aligned}$$

En $(*)$ estamos usando que la sucesión $\{\bigcup_{m \geq n} A_m\}$ es decreciente. \square

Teorema 3.8 (Segundo Lema de Borel-Cantelli). Sea (Ω, \mathcal{A}, P) un espacio de probabilidad y consideremos $\{A_n\} \subset \mathcal{A}$ una sucesión tal que $\sum_{n \geq 1} P(A_n) = \infty$. Entonces

$$P\left(\limsup_n A_n\right) = 1.$$

Demostración.

$$\begin{aligned} P\left(\limsup_n A_n\right) &= P\left(\bigcap_{n \geq 1} \bigcup_{m \geq n} A_m\right) = 1 - P\left[\left(\bigcap_{n \geq 1} \bigcup_{m \geq n} A_m\right)^c\right] \\ &= 1 - P\left(\bigcup_{n \geq 1} \bigcap_{m \geq n} A_m^c\right) = 1 - P\left(\lim_{n \rightarrow \infty} \bigcap_{m \geq n} A_m^c\right) \\ &= 1 - \lim_{n \rightarrow \infty} P\left(\bigcap_{m \geq n} A_m^c\right) = 1 - \lim_{n \rightarrow \infty} \prod_{m \geq n} P(A_m^c) \\ &= 1 - \lim_{n \rightarrow \infty} \prod_{m \geq n} (1 - P(A_m)). \end{aligned}$$

Observamos que

$$\prod_{m \geq n} (1 - P(A_m)) \stackrel{(*)}{=} \prod_{m \geq n} e^{-P(A_m)} = e^{-\sum_{m \geq n} P(A_m)} = 0.$$

En $(*)$ usamos que si $x \geq 0$, entonces $1 - x \leq e^{-x}$. Finalmente, gracias a lo anterior

$$P\left(\limsup_n A_n\right) = 1.$$

□

Corolario 3.9 (Ley 0-1 de Borel-Cantelli). *Sea (Ω, \mathcal{A}, P) un espacio de probabilidad y consideremos $\{A_n\} \subset \mathcal{A}$ una sucesión de sucesos independientes, entonces $P(\limsup_n A_n)$ o bien es 0, o bien es 1.*

Sean X_n variables aleatorias en (Ω, \mathcal{A}, P) . Definimos

$$\Omega_1 = \{\omega \in \Omega : \liminf_n X_n(\omega) = \limsup_n X_n(\omega)\},$$

que es el conjunto de $\omega \in \Omega$ para los cuales existe $\lim_n X_n$.

Teorema 3.10. *Sean X_i variables aleatorias en (Ω, \mathcal{A}, P) . Entonces $\inf_n X_n$, $\sup_n X_n$, $\liminf_n X_n$ y $\limsup_n X_n$ son variables aleatorias.*

Demostración. Sea $Y = \inf_n X_n$ y fijemos $b \in \mathbb{R}$. Entonces

$$Y^{-1}((-\infty, b)) = \left\{ \omega \in \Omega : \inf_n X_n(\omega) < b \right\} = \bigcup_{n \geq 1} \{\omega \in \Omega : X_n(\omega) < b\}$$

$$\bigcup_{n \geq 1} X_n^{-1}((-\infty, b)) \in \mathcal{A},$$

es decir, Y es variable aleatoria. Observamos que $\sup_n X_n = -\inf_n (-X_n)$, $\liminf_n X_n = \sup_n \inf_{m \geq n} X_m$ y $\limsup_n X_n = \inf_n \sup_{m \geq n} X_m$. Aplicar una función medible a una variable aleatoria, nos sigue dando una variable aleatoria, por tanto, todo lo anterior eran variables aleatorias. □

Corolario 3.11. Ω_1 es medible.

Definición 3.12. Sea $\{X_n\}$ una sucesión de variables aleatorias en (Ω, \mathcal{A}, P) . Decimos que X_n converge casi seguro si $P(\Omega_1) = 1$. En tal caso, $X := \lim_n X_n$ y $X_n \xrightarrow{c.s.} X$.

Teorema 3.13. $X_n \xrightarrow{c.s.} X$ si y solo si $P(\liminf_n y_{n,k}) = 1$ para todo k , siendo

$$y_{n,k} = \left\{ \omega \in \Omega : |X_n(\omega) - X(\omega)| < \frac{1}{k} \right\}.$$

Teorema 3.14. $X_n \xrightarrow{c.s.} X$ si y solo si $P(\limsup_n y_{n,k}^c) = 0$ para todo k .

Definición 3.15. Diremos que X_n converge en probabilidad a X si para todo $\varepsilon > 0$

$$P(y_{n,\varepsilon}) \xrightarrow{n \rightarrow \infty} 1,$$

siendo

$$y_{n,\varepsilon} = \{\omega \in \Omega : |X_n(\omega) - X(\omega)| < \varepsilon\}.$$

Teorema 3.16. *El límite en probabilidad es único casi seguro (c.s.).*

Teorema 3.17. Si $X_n \xrightarrow{c.s.} X$, entonces $X_n \xrightarrow{p} X$.

Teorema 3.18. Si $X_n \xrightarrow{p} X$, entonces existe alguna subsucesión X_{n_k} de X tal que $X_{n_k} \xrightarrow{c.s.} X$.

Teorema 3.19. $X_n \xrightarrow{p} X$ si y solo si toda subsucesión contiene una subsucesión convergente casi seguro.

Teorema 3.20. La convergencia en probabilidad implica la convergencia en distribución.

Teorema 3.21. Sean X_n, X variables aleatorias en (Ω, \mathcal{A}, P) con $X \sim \delta(c)$, c constante. Entonces $X_n \xrightarrow{p} X$ si y solo si $X_n \xrightarrow{d} X$.

Consideremos el espacio

$$L^p(\Omega, \mathcal{A}, P) = \{X \text{ v.a.} : E[|X|^p] < \infty\}.$$

Se puede probar que $(L^p, \|\cdot\|_p)$ es un espacio métrico, siendo

$$\|X\|_p = \left(\int_{\Omega} |X|^p dP \right)^{1/p}$$

Definición 3.22. Diremos que X_n converge a X en L^p , $X_n \xrightarrow{L^p} X$, cuando $\|X_n - X\|_p \xrightarrow{n \rightarrow \infty} 0$.

Diremos que

- Converge en media si $p = 1$.
- Converge en media cuadrática si $p = 2$.

Desigualdad de Markov: Sea X variable no negativa y $a > 0$, entonces

$$P(X \geq a) \leq \frac{E[X]}{a}.$$

Si además $X \in L^p$

$$P(X \geq a) \leq \frac{E[X^p]}{a^p}.$$

Teorema 3.23. $X_n, X \in L^p$. Si $X_n \xrightarrow{L^p} X$, entonces $X_n \xrightarrow{p} X$.

Teorema 3.24. El límite en L^p es único.

Teorema 3.25. Sean $X_n, X \in L^p$ tales que $X_n \xrightarrow{p} X$. Si existe $Y \in L^p$ tal que $|X_n| \leq Y$ para todo n , entonces $X_n \xrightarrow{L^p} X$.

Ley débil de los grandes números (LDGN)

Sean X_1, X_2, \dots variables aleatorias en (Ω, \mathcal{A}, P) . Definimos

$$S_n = X_1 + \dots + X_n, \quad n \geq 1.$$

La sucesión $\{X_n\}$ verifica la ley débil de los grandes números si existen sucesiones numéricas $\{a_n\}$ y $\{b_n\}$ con $b_n \uparrow \infty$ tales que

$$\frac{S_n - a_n}{b_n} \xrightarrow{p} 0.$$

Teorema 3.26 (Bernoulli, 1713). Sean X_1, X_2, \dots variables aleatorias independientes en (Ω, \mathcal{A}, P) con $X_i \sim \text{Ber}(p)$, $0 < p < 1$. Entonces

$$\frac{S_n}{n} \xrightarrow{p} p,$$

es decir, verifica LDGN para $a_n = np$ y $b_n = n$.

Teorema 3.27 (Chebyshev). Sea $\{X_n\}$ una sucesión de variables aleatorias independientes con media μ y varianza σ^2 constantes. Entonces

$$\frac{S_n}{n} \xrightarrow{p} \mu$$

Teorema 3.28 (Chebyshev). Sea $\{X_n\}$ una sucesión de variables aleatorias independientes con varianza acotada por una constante. Entonces

$$\frac{S_n - E[S_n]}{n} \xrightarrow{p} 0$$

Teorema 3.29 (Markov). Sea $\{X_n\}$ una sucesión de variables aleatorias independientes tal que $\text{Var}[S_n/n] \xrightarrow{n \rightarrow \infty} 0$. Entonces

$$\frac{S_n - E[S_n]}{n} \xrightarrow{p} 0$$

Teorema 3.30 (Khinchin). Sea $\{X_n\}$ una sucesión de variables aleatorias independientes e idénticamente distribuidas con media μ finita. Entonces

$$\frac{S_n}{n} \xrightarrow{p} \mu$$

Ley fuerte de los grandes números (LFGN)

Sean X_1, X_2, \dots variables aleatorias en (Ω, \mathcal{A}, P) . La sucesión $\{X_n\}$ verifica la ley fuerte de los grandes números si existen sucesiones numéricas $\{a_n\}$ y $\{b_n\}$ con $b_n \uparrow \infty$ tales que

$$\frac{S_n - a_n}{b_n} \xrightarrow{c.s.} 0.$$

Lema 3.31. Sea $\{X_n\}$ sucesión de variables aleatorias. Entonces $\sum_{n=1}^{\infty} X_n$ converge casi seguro si y solo si

$$\lim_{n \rightarrow \infty} \lim_{m \rightarrow \infty} P \left(\max_{1 \leq j \leq m} |S_j - S_m| \geq \varepsilon \right) = 0$$

para todo $\varepsilon > 0$.

Teorema 3.32 (Criterio de convergencia de Kolmogórov). Sea $\{X_n\}$ una sucesión de variables aleatorias independientes con $\sum_{n=1}^{\infty} \text{Var}[X_n] < \infty$. Entonces $\sum_{n=1}^{\infty} (X_n - E[X_n]) < \infty$ c.s.

Teorema 3.33 (Recíproco de Kolmogórov). Sea $\{X_n\}$ una sucesión de variables aleatorias independientes. Si existe una constante $c > 0$ tal que $|X_n| < c$ c.s. para todo n . Entonces

$$\sum_{n=1}^{\infty} (X_n - E[X_n]) < \infty \text{ c.s.} \iff \sum_{n=1}^{\infty} \text{Var}[X_n] < \infty.$$

Corolario 3.34. Sea $\{X_n\}$ una sucesión de variables aleatorias tales que $|X_n| < c$ c.s. para algún $c > 0$ constante. Si $\sum_{n=1}^{\infty} X_n < \infty$ c.s., entonces también convergen las series $\sum_{n=1}^{\infty} (X_n - E[X_n])$ c.s., $\sum_{n=1}^{\infty} E[X_n]$ y $\sum_{n=1}^{\infty} \text{Var}[X_n]$.

Teorema 3.35 (Condición suficiente de Kolmogórov). Sea $\{X_n\}$ una sucesión de variables aleatorias independientes con varianza finita. Si $\sum_{n=1}^{\infty} \frac{\text{Var}[X_n]}{n^2} < \infty$, entonces $\{X_n\}$ verifica la ley fuerte de los grandes números, es decir,

$$\frac{S_n}{n} \xrightarrow{c.s.} 0$$

Lema 3.36 (Kronecker). Sea $\{X_n\}$ una sucesión de variables aleatorias y $\{a_n\}$ una sucesión de números reales tal que $a_n \uparrow \infty$. Si $\sum_{n=1}^{\infty} \frac{X_n}{a_n} < \infty$ c.s, entonces $\frac{1}{a_n} \sum_{k=1}^n X_k \xrightarrow[n \rightarrow \infty]{c.s.} 0$.

Definición 3.37. Sean $\{X_n\}$ una sucesión de variables aleatorias y $\{c_n\}$ una sucesión de números reales no negativos. Se define la sucesión de variables aleatorias truncadas como $\{Y_n\}$ donde

$$Y_n = X_n \mathbb{I}_{\{|X_n| < c_n\}}.$$

Definición 3.38. Dos sucesiones de variables aleatorias $\{X_n\}$ e $\{Y_n\}$ son equivalentes en convergencia cuando $\sum_{n=1}^{\infty} P(X_n \neq Y_n) = 0$.

Teorema 3.39. Si $\{X_n\}$ e $\{Y_n\}$ son equivalentes en convergencia, entonces

1. $P(\limsup_n \{X_n \neq Y_n\}) = 0$.
2. $\sum_{n=1}^{\infty} X_n < \infty$ c.s si y solo si $\sum_{n=1}^{\infty} Y_n < \infty$ c.s.
3. $\frac{1}{n} \sum_{k=1}^n (X_k - Y_k) < \infty \xrightarrow[n \rightarrow \infty]{c.s.} 0$.

Teorema 3.40 (3 series de Kolmogórov). Sean $\{X_n\}$ una sucesión de variables aleatorias independientes y $\{X_n^c\}$ una sucesión de variables aleatorias X_n truncadas, para alguna constante $c > 0$. Si existe $c > 0$ tal que las series $\sum_{n=1}^{\infty} P(X_n \neq X_n^c)$, $\sum_{n=1}^{\infty} E[X_n^c]$ y $\sum_{n=1}^{\infty} \text{Var}[X_n^c]$ convergen, entonces $\sum_{n=1}^{\infty} X_n$ converge c.s.

Recíprocamente, si $\sum_{n=1}^{\infty} X_n$ converge c.s, entonces las tres series convergen para todo $c > 0$.

Lema 3.41. Sea X una variable aleatoria. Se tiene que $E[|X|] < \infty$ si y solo si $\sum_{n=1}^{\infty} P(|X| \geq n) < \infty$.

Teorema 3.42 (Ley fuerte de los grandes números). Sean X_1, X_2, \dots variables aleatorias independientes e igualmente distribuidas con $E[X_1] = \mu < \infty$, entonces

$$\frac{S_n}{n} \xrightarrow{c.s.} \mu.$$

Recíprocamente, si $\frac{S_n}{n} \xrightarrow{c.s.} c$ (constante), entonces $E[X_1] = c$.

Teorema 3.43 (Teorema central del límite). Sean X_1, X_2, \dots variables aleatorias, independientes e idénticamente distribuidas con $E[X_1] = \mu < \infty$ y $\text{Var}[X_1] = \sigma^2 < \infty$. Entonces

$$\frac{\sqrt{n}}{\sigma} \left(\frac{S_n}{n} - \mu \right) \xrightarrow{d} Z \sim N(0, 1).$$

Teorema 3.44 (TCL de Lindeberg-Feller). Sean X_1, X_2, \dots variables aleatorias, independientes con $E[X_n] = \mu_n < \infty$ y $\text{Var}[X_n] = \sigma_n^2 < \infty$. Definimos $s_n^2 := \text{Var}[S_n] = \sum_{j=1}^n \sigma_j^2$. Entonces

1. $\frac{1}{s_n} \sum_{j=1}^n (X_j - \mu_j) \xrightarrow{d} Z \sim N(0, 1)$,
2. $\max_{1 \leq j \leq n} \frac{\sigma_j^2}{s_n^2} \xrightarrow[n \rightarrow \infty]{} 0$

es equivalente a

$$L_n(\varepsilon) = \frac{1}{s_n^2} \sum_{j=1}^n \int_{|x - \mu_j| > \varepsilon s_n} (x - \mu_j)^2 dF_j(x) \xrightarrow[n \rightarrow \infty]{} 0.$$